Computer Vision

Vision Transformer

Master Technische Informatik / Medieninformatik

Prof. Dr. Kristian Hildebrand
khildebrand@bht-berlin.de

Questions

- What does the ‘G’ stand for in ‘GPT?
- Which technical problem solves ChatGPT?
- How do we measure similarities?
- What are Tokens?
- What are Tokens in Images?
- What is an embedding?
- Tokens are a sequence? How do I learn?
- What is a context size?
- Why positional encoding?
- Q,K, V Matrices? What are they for?

Ausgewählte Arten von Neuronalen Netzen (vereinfachte Darstellung)

Perceptron

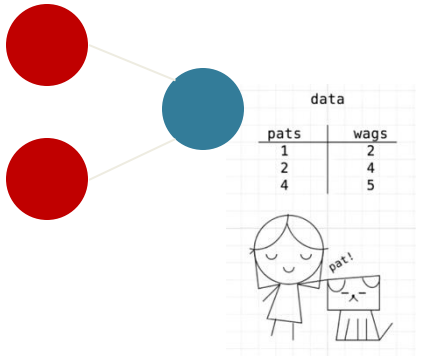

Recurrent

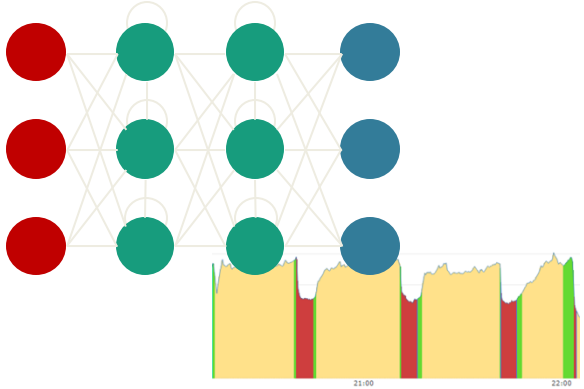

Convolutional

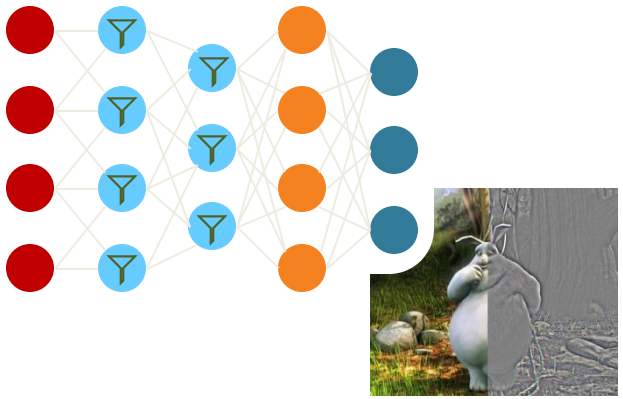

Feed Forward

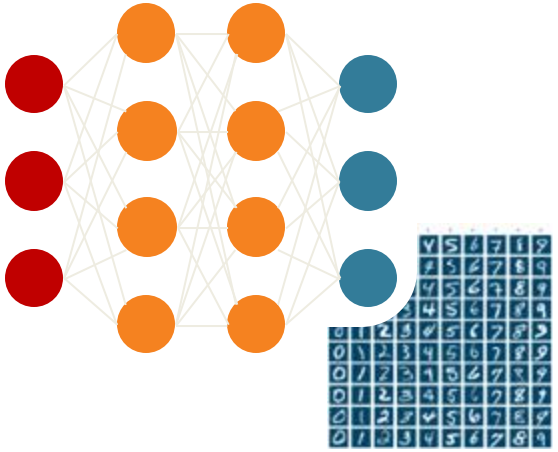

Long / Short Term Memory

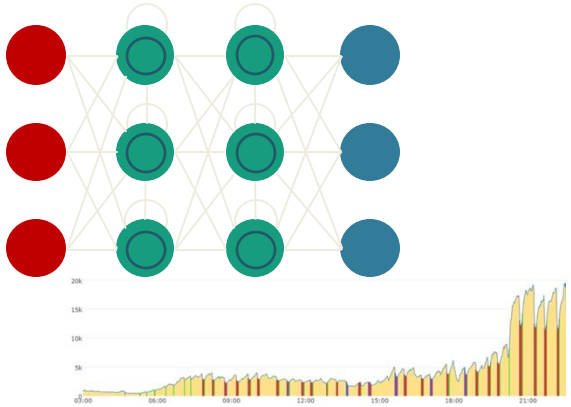

Attention-based

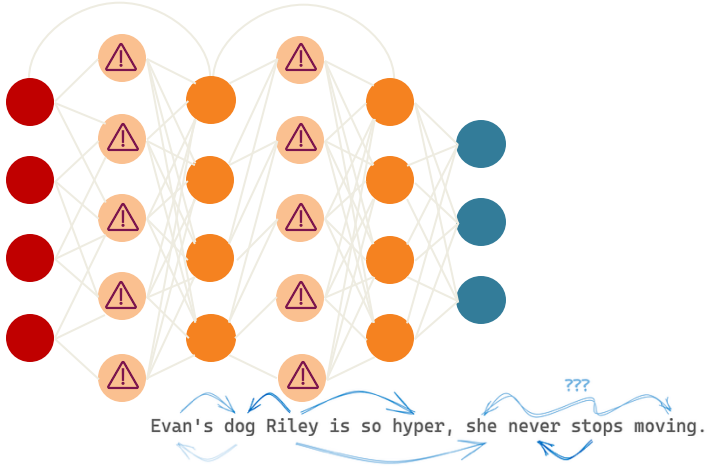

- Input Cell
- Output Cell
- Hidden Cell
- Recurrent Cell
- Memory Cell
- Convolution
- Attention Weights

Eigene Darstellung; Inspiriert von: https://www.researchgate.net/figure/Different-neural-networks-architecture-https-wwwasimovinstituteorg-author_fig1_374078230

Vision Transformer (ViT)

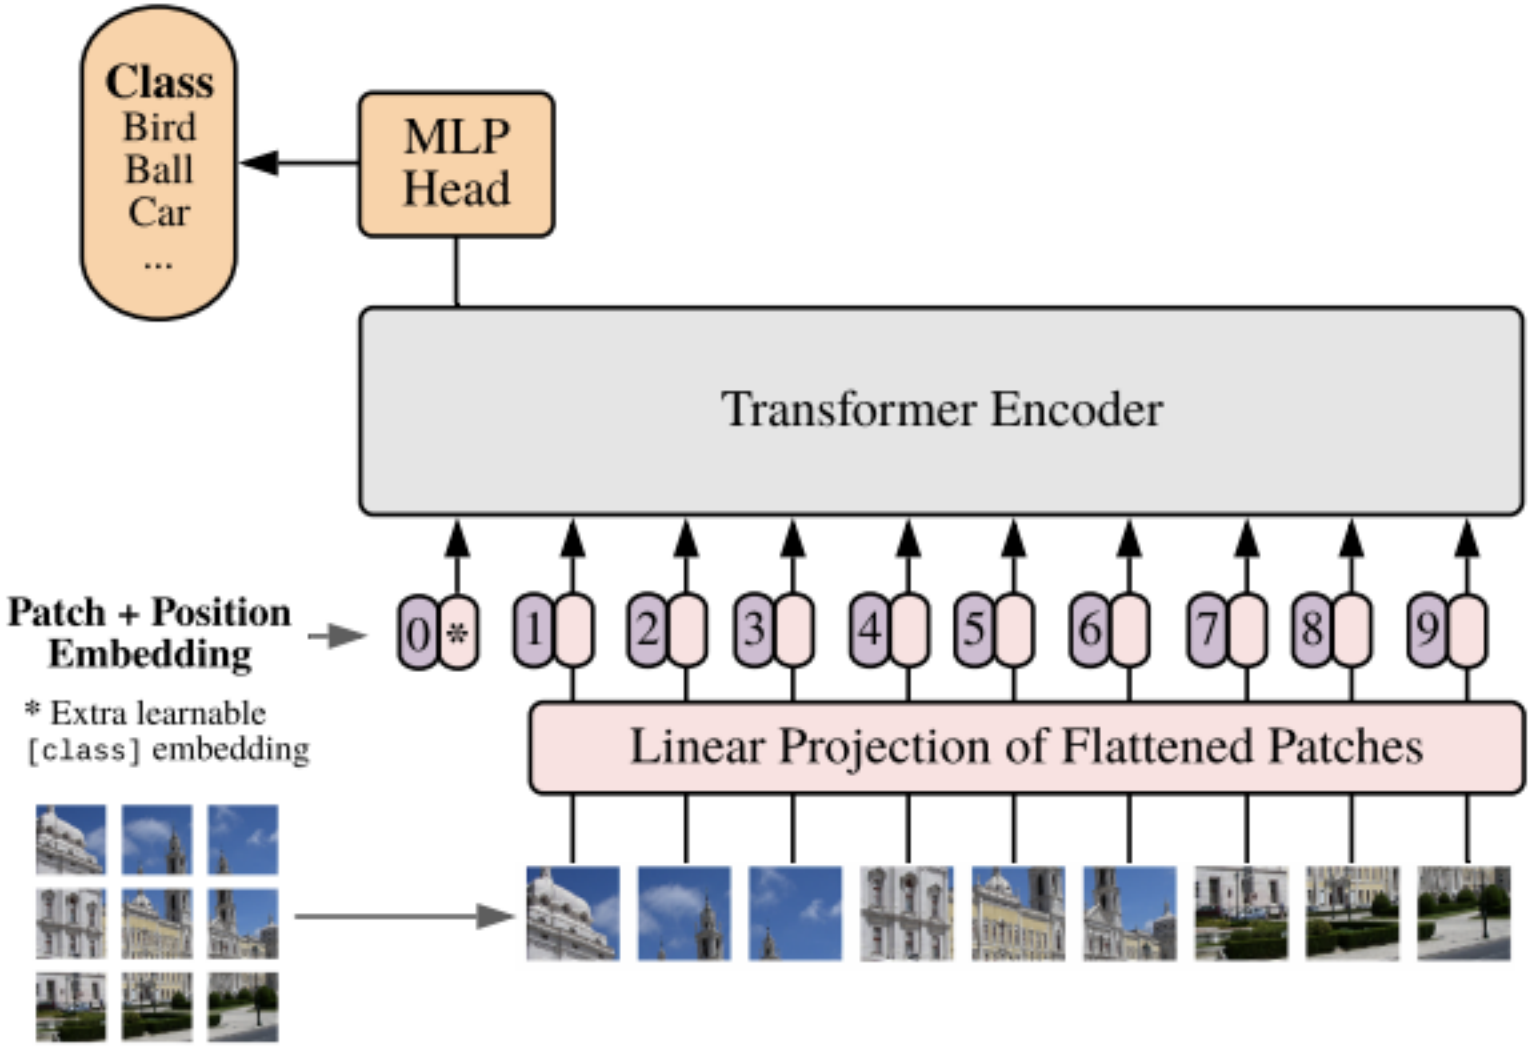

Dosovitskiy et al. in An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR 2021

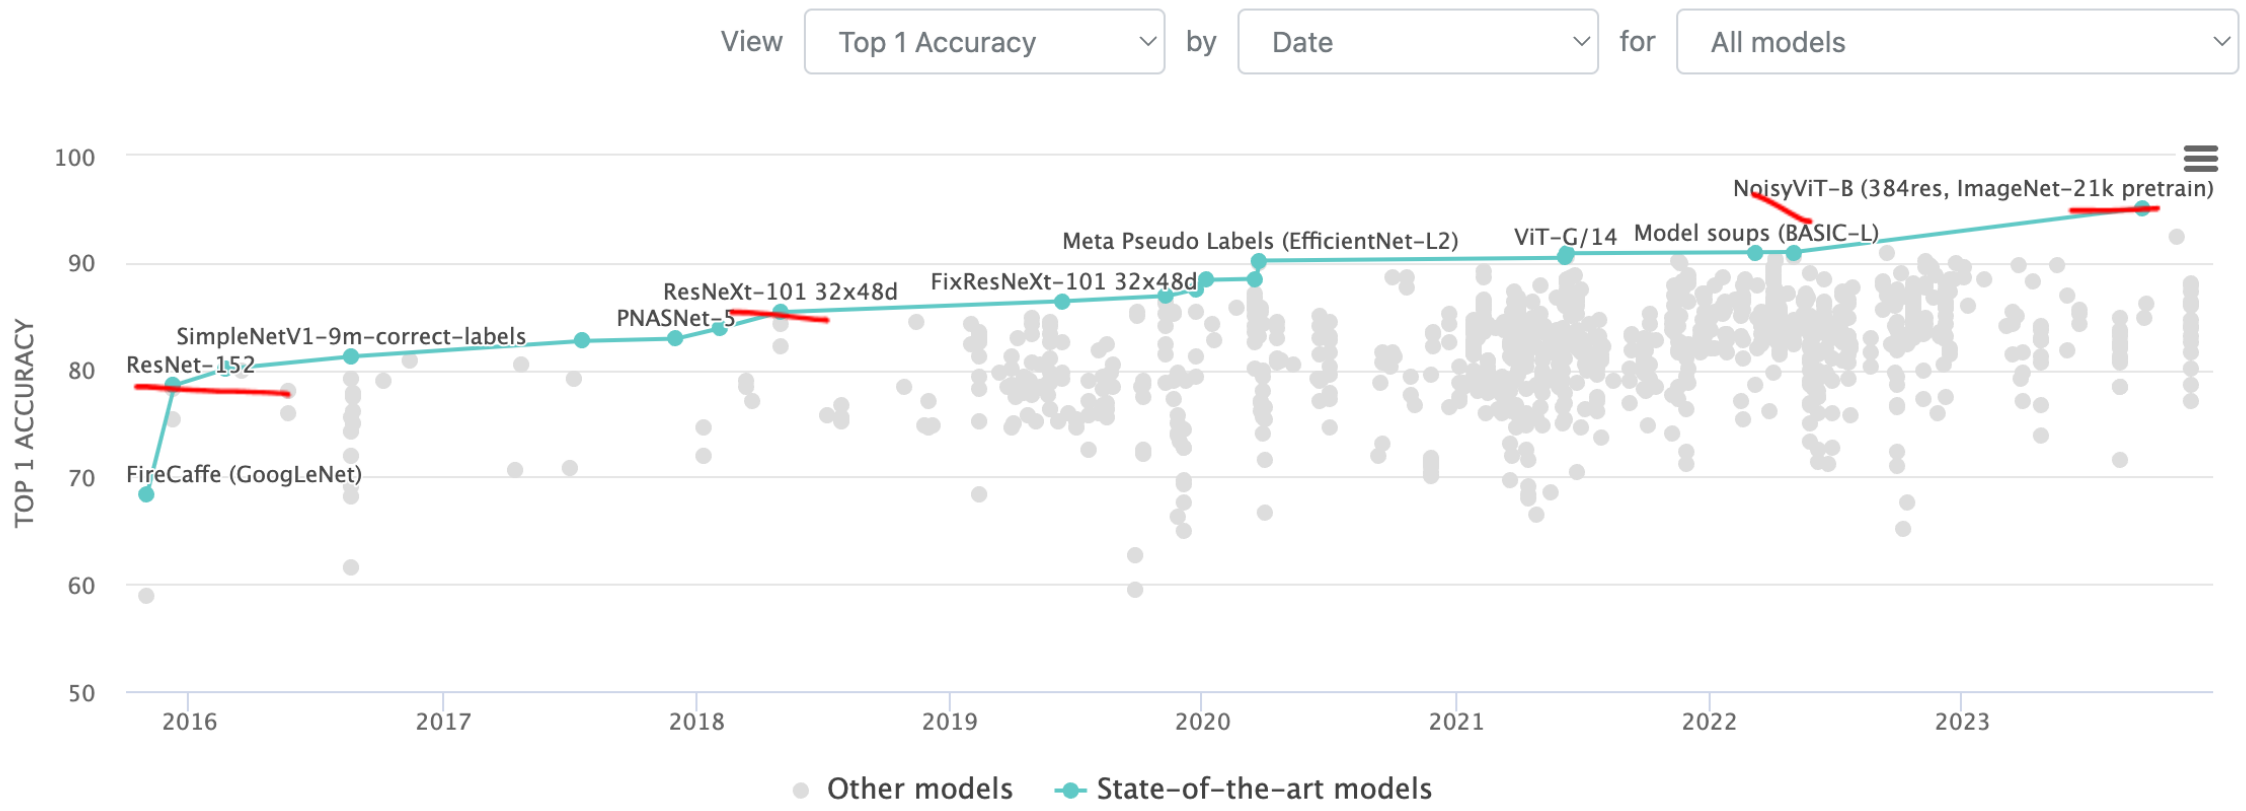

https://paperswithcode.com/sota/image-classification-on-imagenet

Sequence to Sequence Learning and Attention

- **Sequence-to-Sequence** (or Seq2Seq) - a neural net that transforms **given sequence into another sequence**
  - Good at translation
  - Capture time constraints but also spatial constraints

- Famous example: **Long-Short-Term-Memory (LSTM)**-based models

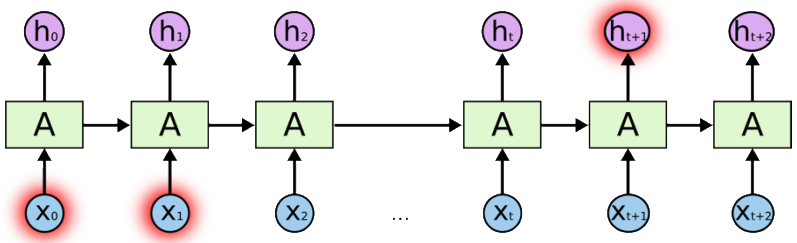

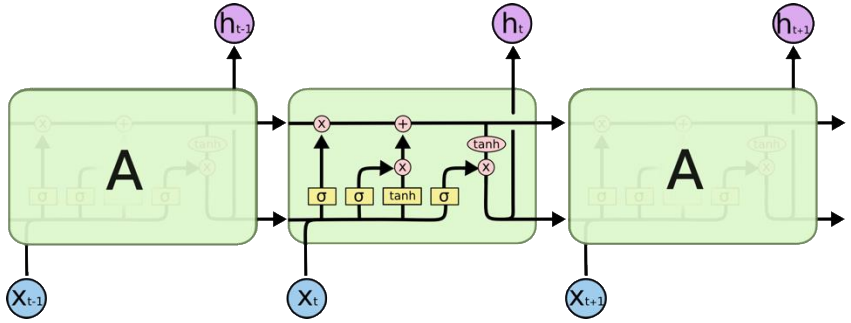

https://colah.github.io/posts/2015-08-Understanding-LSTMs/

Recurrent Neural Networks

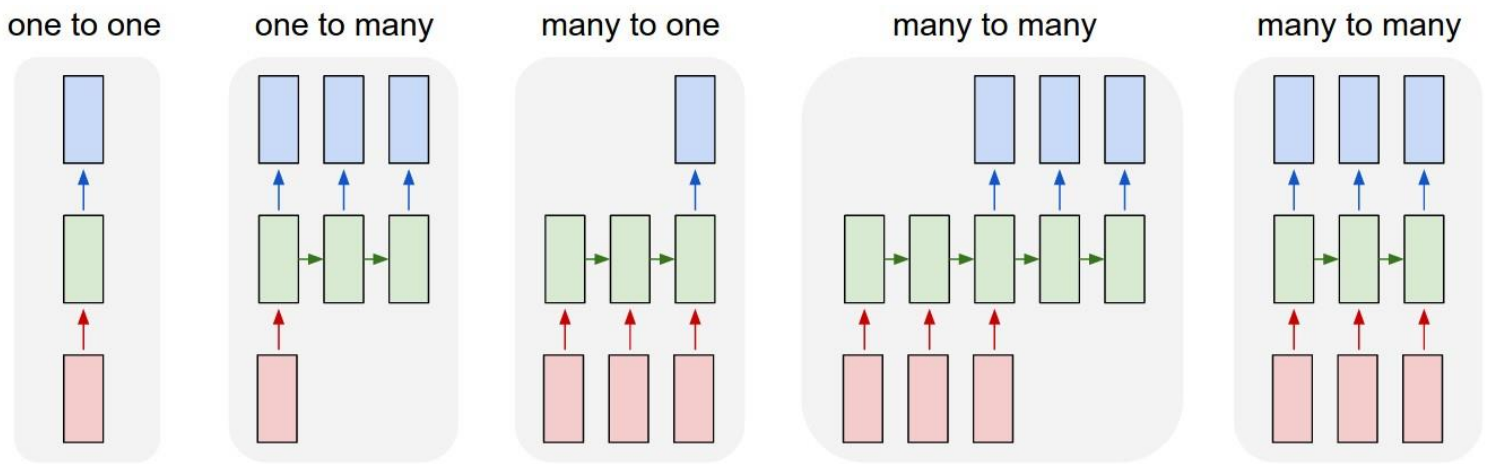

http://karpathy.github.io/2015/05/21/rnn-effectiveness/

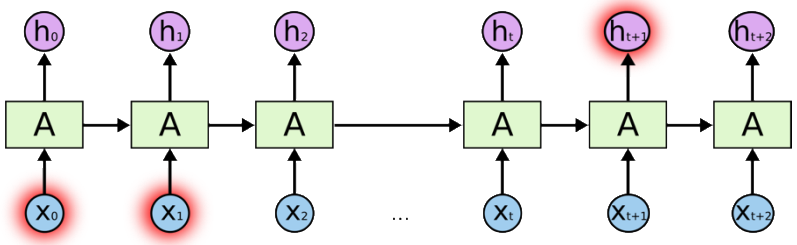

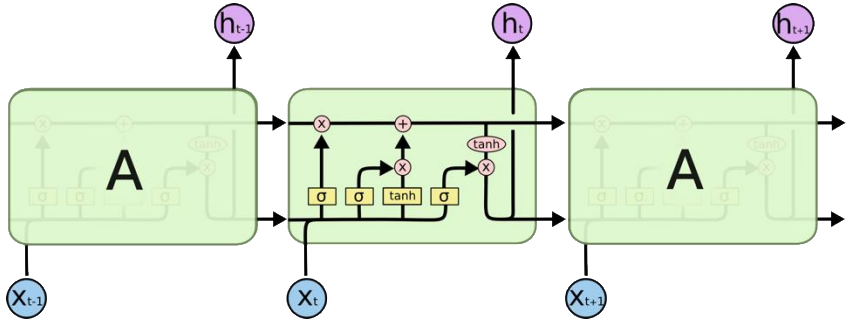

https://colah.github.io/posts/2015-08-Understanding-LSTMs/

Char-RNN

Training data: Linux Kernel C Code

```c
/*
 * Increment the size file of the new incorrect UI_FILTER group information
 * of the size generatively.
 */
static int indicate_policy(void)
{
  int error;
  if (fd == MARN_EPT) {
    /*
     * The kernel blank will coeld it to userspace.
     */
    if (ss->segment < mem_total)
      unblock_graph_and_set_blocked();
    else
      ret = 1;
    goto bail;
  }
  segaddr = in_SB(in.addr);
  selector = seg / 16;
  setup_works = true;
  for (i = 0; i < blocks; i++) {
    seq = buf[i++];
    bpf = bd->bd.next + i * search;
    if (fd) {
      current = blocked;
    }
  }
  rw->name = "Getjbbregs";
  bprm_self_clearl(&iv->version);
  regs->new = blocks[(BPF_STATS << info->historidac)] | PFMR_CLOBATHINC_SECONDS << 12;
  return segtable;
}
```

PixelRNN *[van der Oord et al. 2016]*

- Generate image pixels starting from corner
- Dependency on previous pixels modeled using an RNN (LSTM)

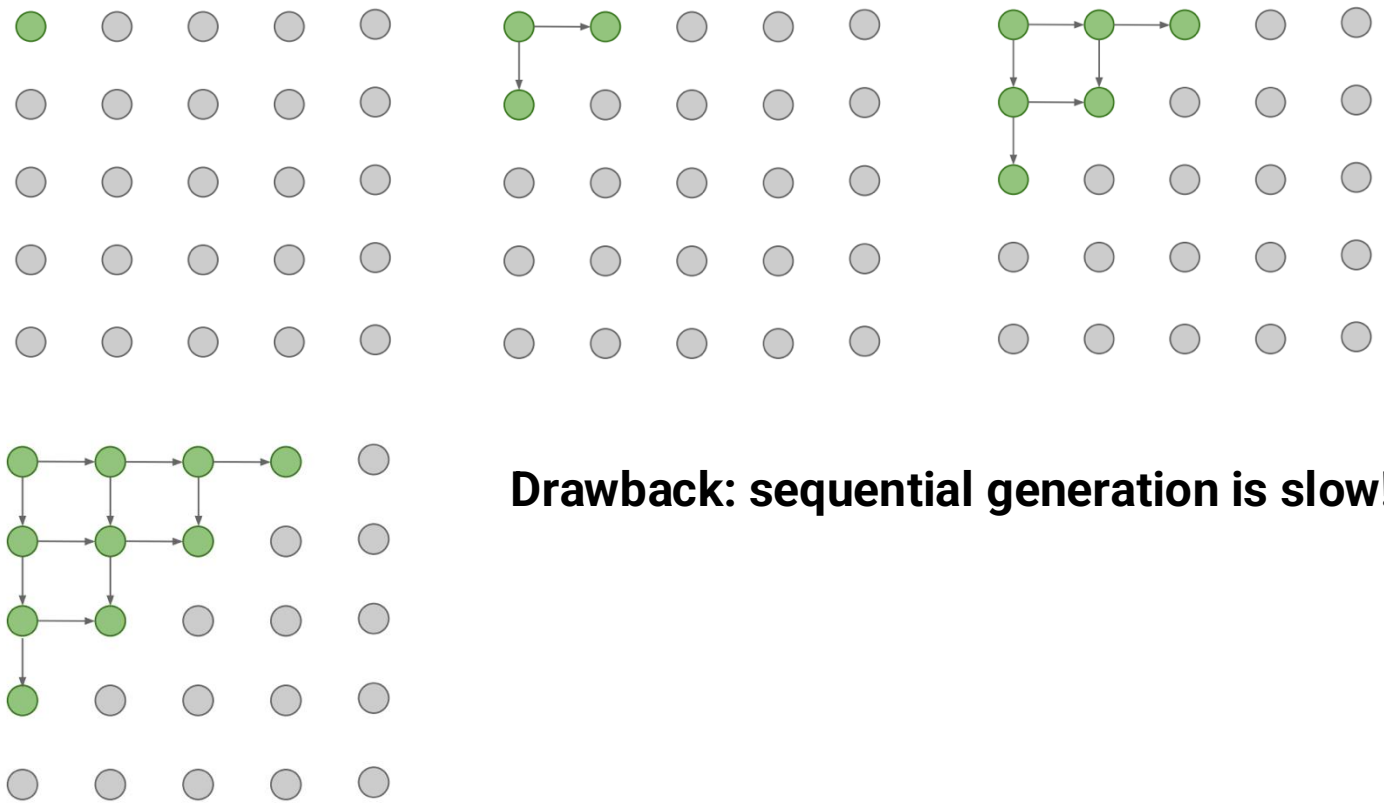

Drawback: sequential generation is slow!

Long-Short-Term-Memory (LSTM)-based models

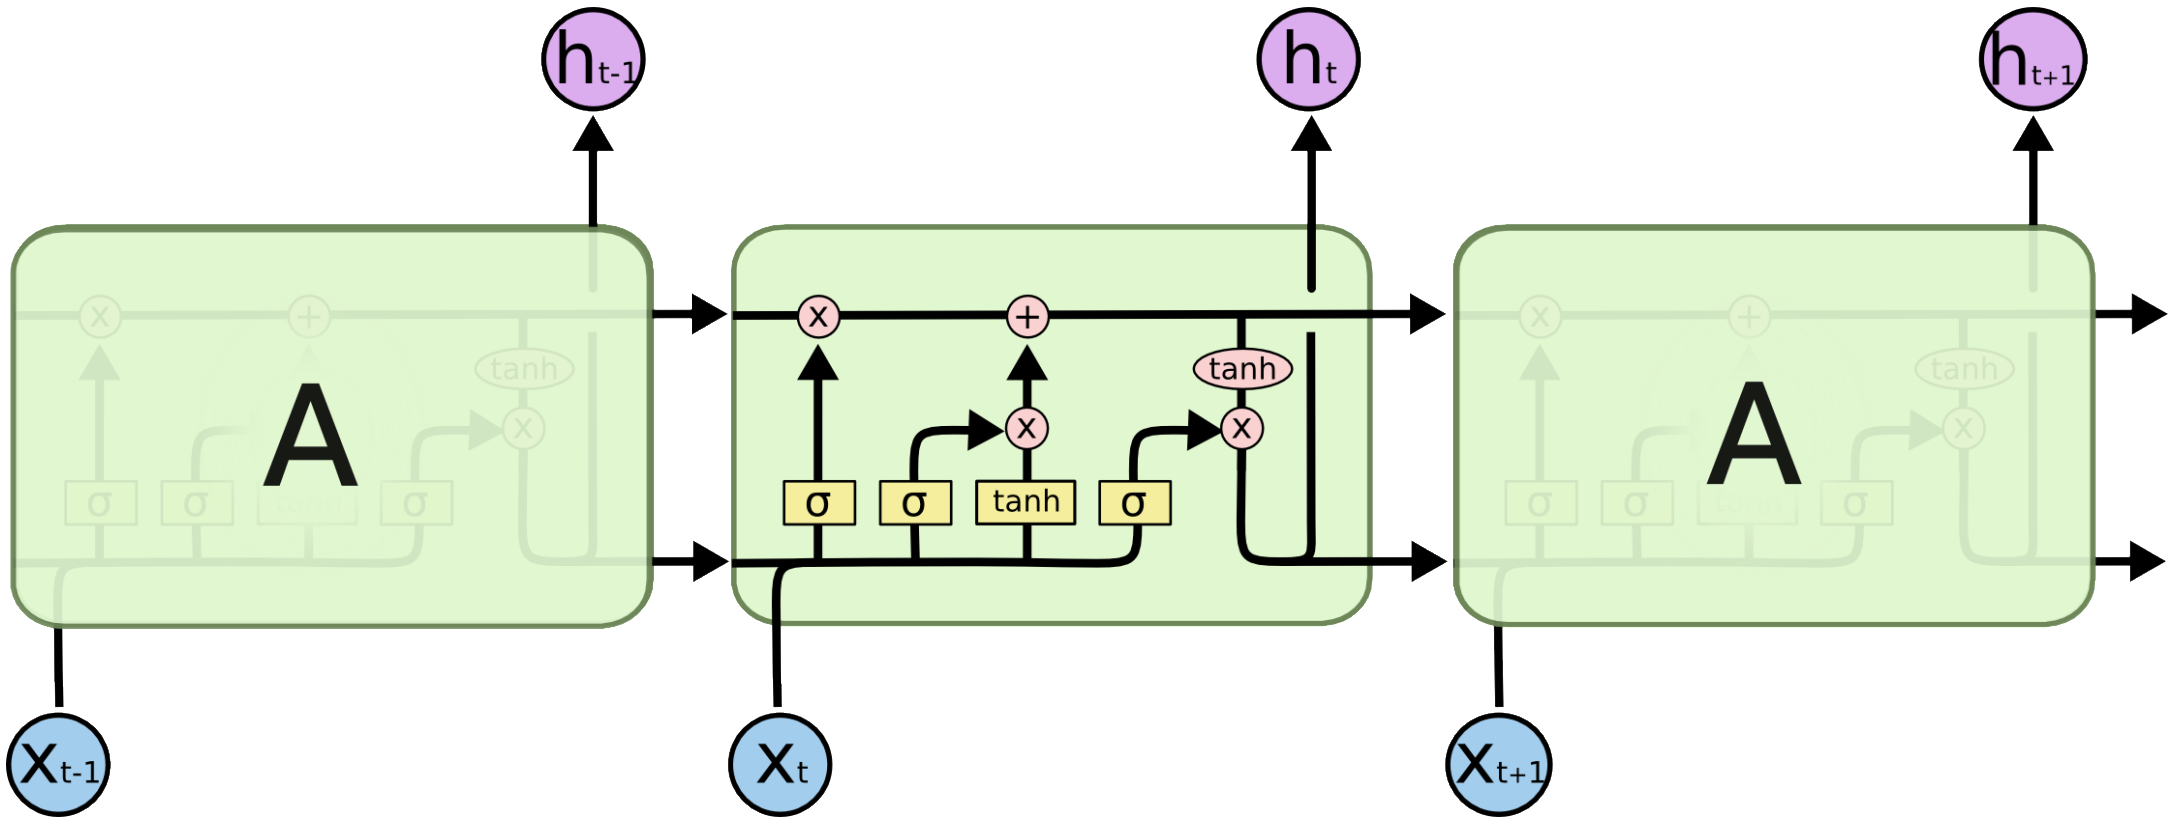

https://colah.github.io/posts/2015-08-Understanding-LSTMs/

Implementation: https://towardsdatascience.com/building-a-lstm-by-hand-on-pytorch-59c02a4ec091

The Transformer

Beantwortung von Fragen in einem Kurs

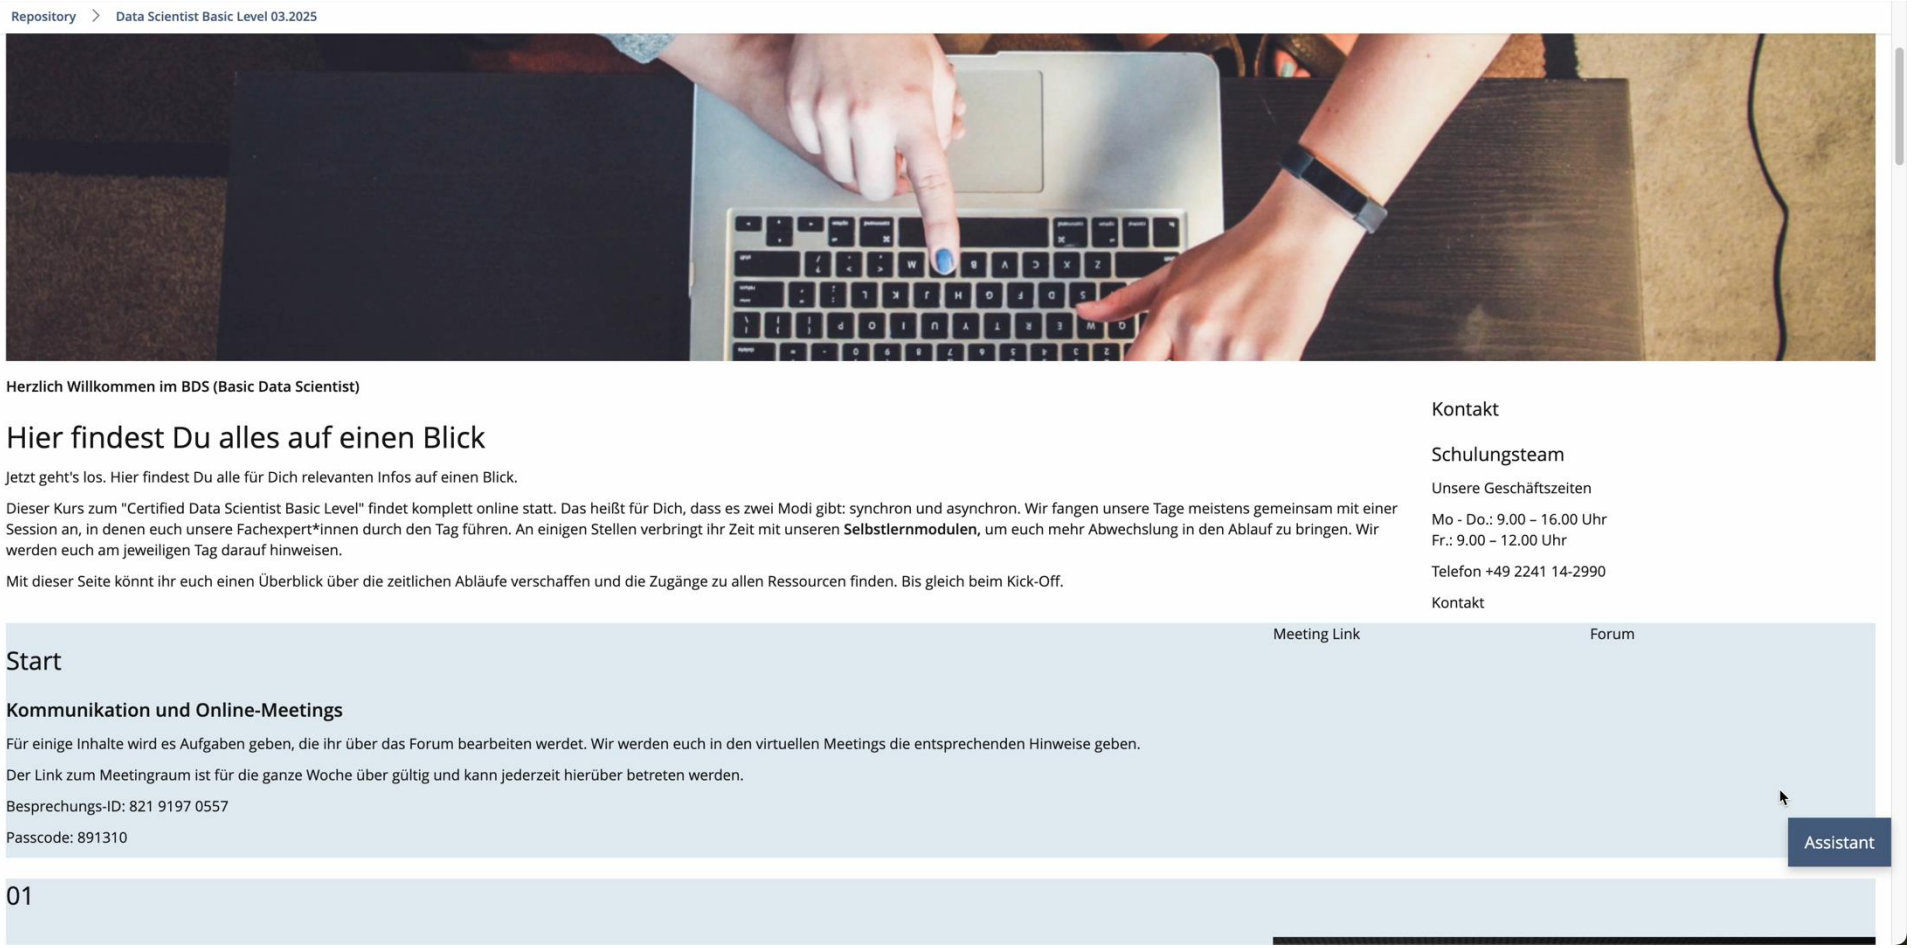

Partner:

Microsoft

Umgesetzt von:

Fraunhofer FOKUS

Unterhaltung über Videoinhalte

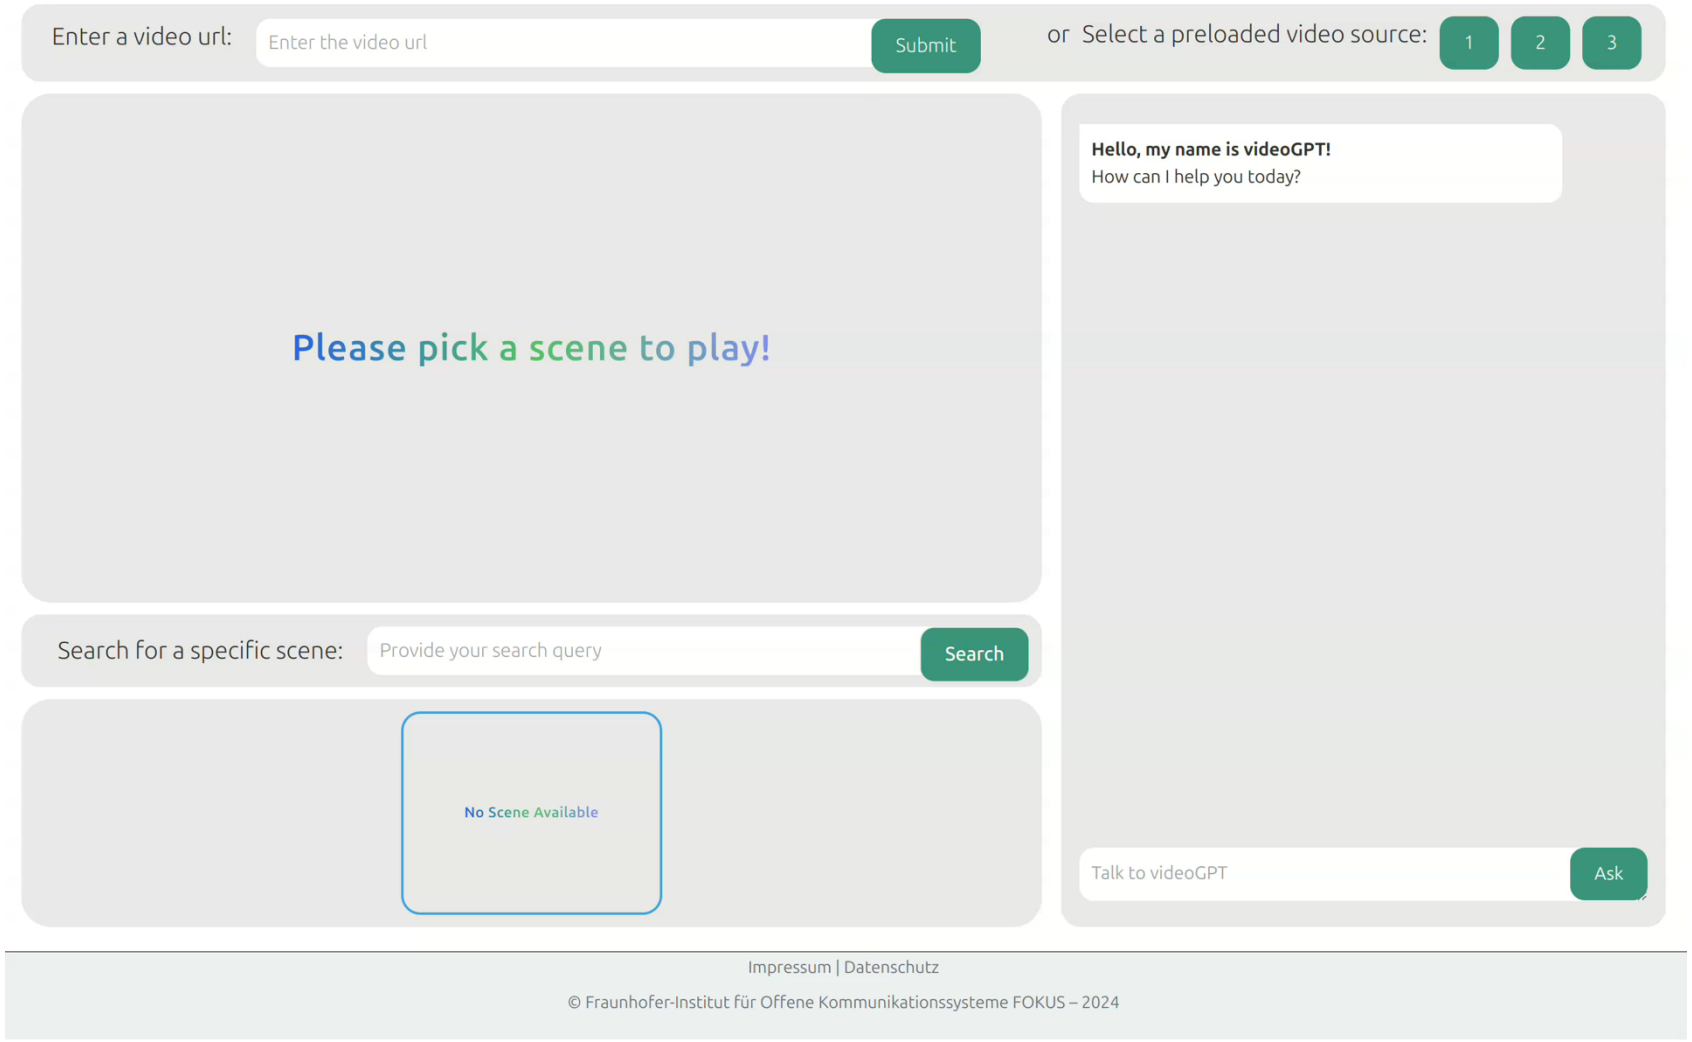

Umgesetzt von:

Fraunhofer FOKUS

https://www.fokus.fraunhofer.de/en/fame/workingareas/ai.html

Maschinelles Lernen

Berlin liegt in

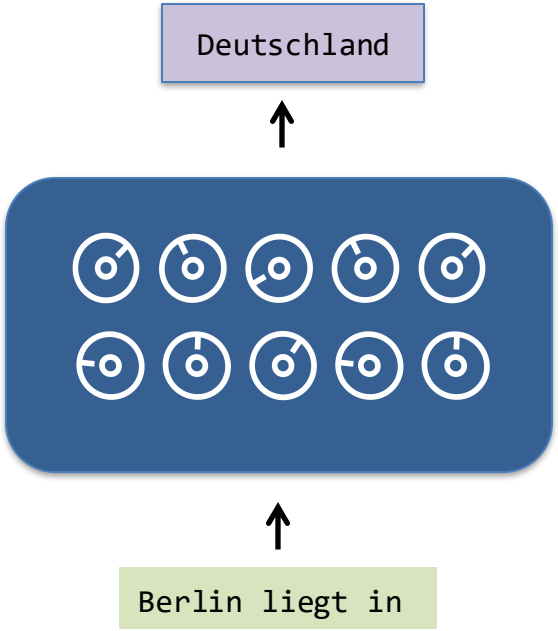

Mir ist es draußen zu kalt

Wenn es regnet bleibe ich zu Hause

Paris ist die Hauptstadt von Frankreich

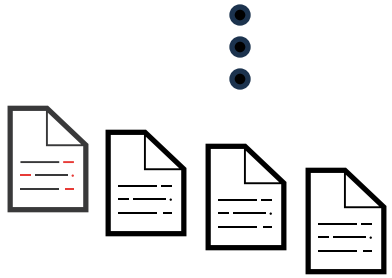

Vor Transformern: Recurrent Neural Networks (RNN)

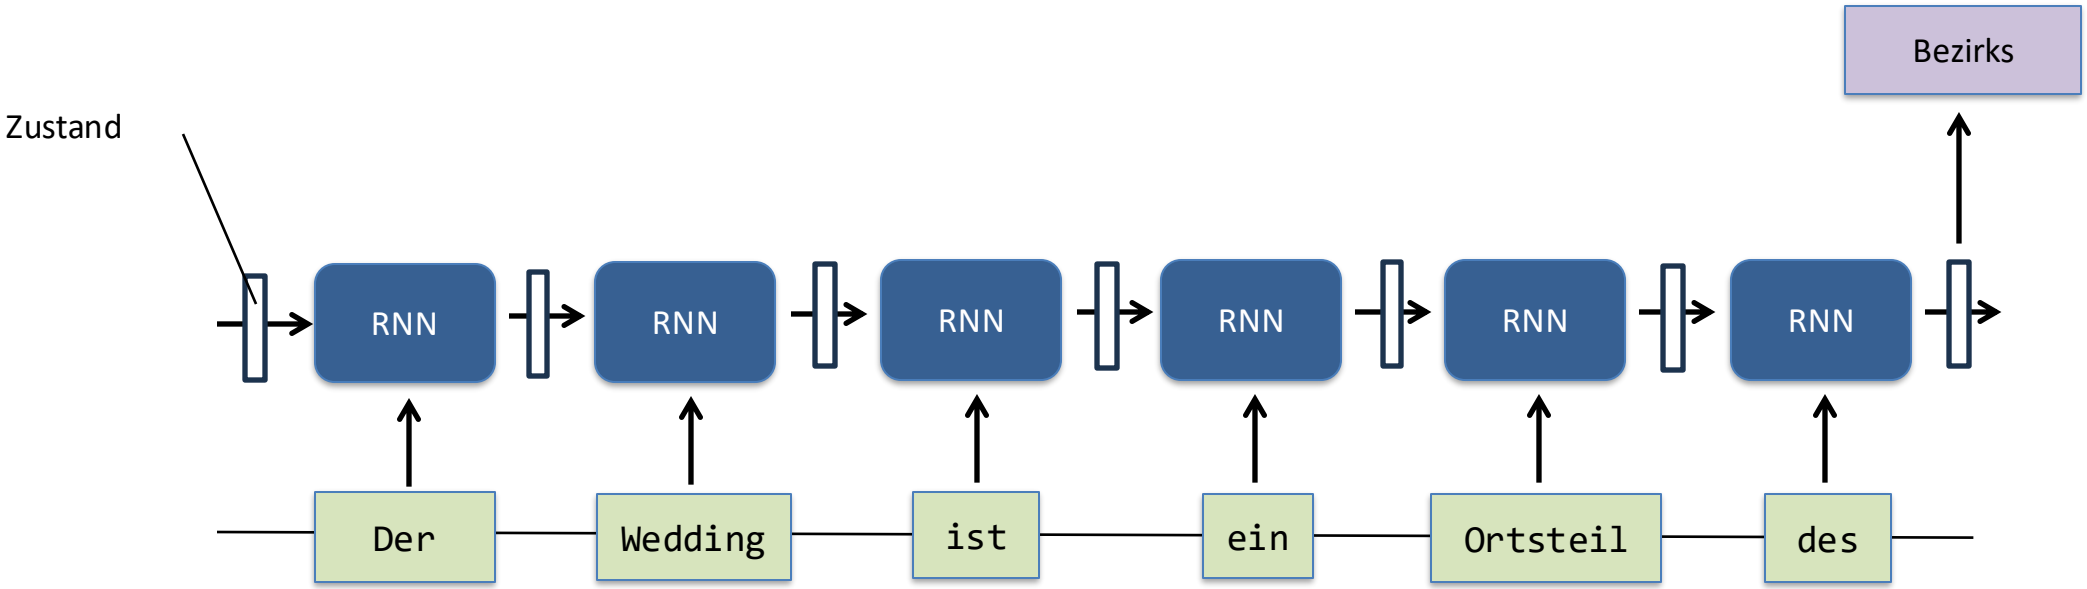

Probleme bei langen Sequenzen

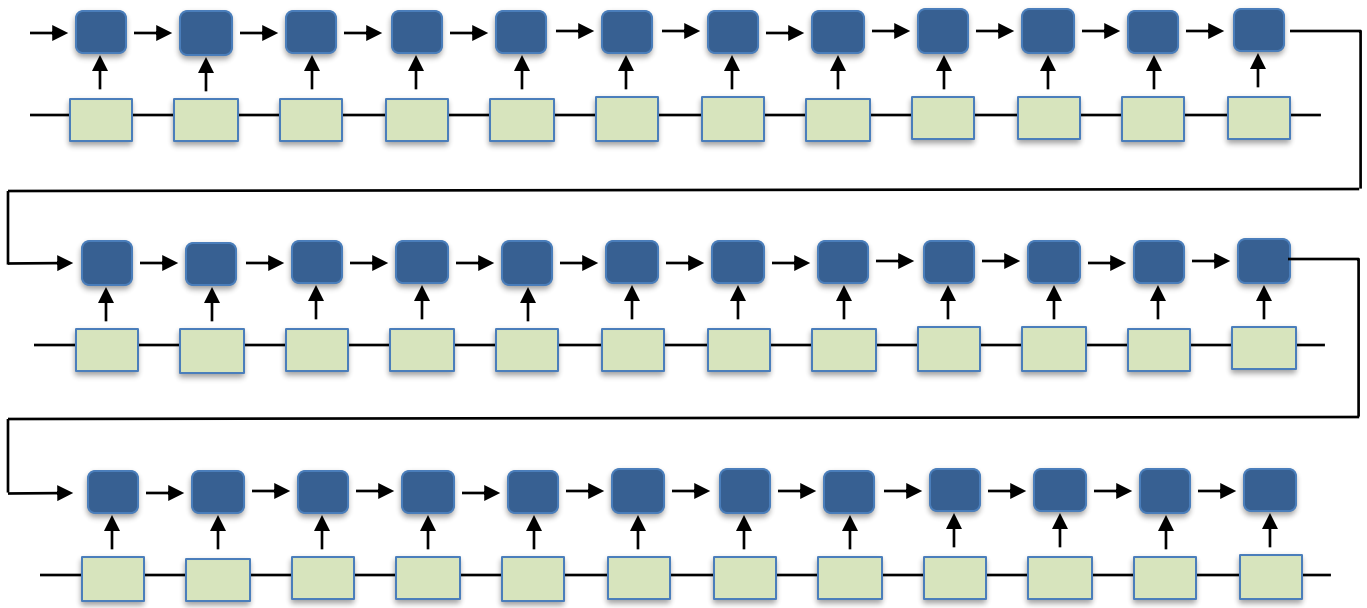

Es war einmal ein König, der hatte eine Frau mit goldenen Haaren, und sie war so schön, daß sich ihresgleichen nicht mehr auf Erden fand. Es geschah, daß sie krank lag, und als fühlte sie bald, daß sie sterben würde, rief sie den König und sprach: »Wenn du nach meinem Tode dich wieder vermählen willst, so nimm keine, die nicht ebenso schön ist, als ich bin, und die nicht solche Haare hat, wie ich habe; das mußt du mir versprechen!« Nachdem es ihr der König versprochen hatte, tat sie die Augen zu und starb.

Der König war lange Zeit nicht zu trösten und dachte nicht daran, eine zweite Frau zu nehmen. Endlich sprachen seine Räte: »Es geht nicht anders, der König muß sich wieder vermählen, damit wir eine Königin haben.« Nun wurden Boten weit und breit herumgeschickt, um eine Braut zu suchen, die an Schönheit der verstorbenen Königin ganz gleichkäme. Es war aber keine in der ganzen Welt zu finden, und wenn man sie auch gefunden hätte, so war doch keine da, die solche goldene Haare gehabt hätte. Also kamen die Boten unverrichteter Sache wieder heim.

Nun hatte der König eine Tochter, die war geradeso schön wie ihre verstorbene Mutter und hatte auch solche goldene Haare. Als sie herangewachsen war, sah sie der König einmal an und sah, daß sie in allem seiner verstorbenen Gemahlin ähnlich war, und fühlte plötzlich eine heftige Liebe zu ihr. Da sprach er zu seinen Räten: »Ich will meine Tochter heiraten, denn sie ist das Ebenbild meiner verstorbenen Frau, und sonst kann ich doch keine Braut finden, die ihr gleicht.« Als die Räte das hörten, erschraken sie und sprachen: »Gott hat verboten, daß der Vater seine Tochter heirate, aus *der* Sünde kann nichts Gutes entspringen, und das Reich wird mit ins Verderben gezogen.« Die Tochter erschrak noch mehr, als sie den Entschluß ihres Vaters vernahm, hoffte aber, ihn von seinem Vorhaben noch abzubringen. Da sagte sie zu ihm: »Eh ich Euren Wunsch erfülle, muß ich erst drei Kleider haben: eins so golden wie die Sonne, eins so silbern wie der Mond und eins so glänzend wie die Sterne; ferner verlange ich einen Mantel von tausenderlei Pelz und Rauchwerk zusammengesetzt, und ein jedes Tier in Eurem Reich muß ein Stück von seiner Haut dazu geben.« Sie dachte aber: Das anzuschaffen ist ganz unmöglich, und ich bringe damit meinen Vater von seinen bösen Gedanken ab. Der König ließ aber nicht ab, und die geschicktesten Jungfrauen in seinem Reiche mußten die drei Kleider weben, eins so golden wie die Sonne, eins so silbern wie der Mond und eins so glänzend wie die Sterne, und seine Jäger mußten alle Tiere im ganzen Reiche auffangen und ihnen ein Stück von ihrer Haut abziehen; daraus ward ein Mantel aus tausenderlei Rauchwerk gemacht. Endlich, als alles fertig war, ließ der König den Mantel herbeiholen, breitete ihn vor ihr aus und sprach: »Morgen soll die Hochzeit sein!«

Als nun die Königstochter sah, daß keine Hoffnung mehr war, ihres Vaters Herz umzuwandeln, so faßte sie den Entschluß zu entfliehen. In der Nacht, während alles schlief, stand sie auf und nahm von ihren Kostbarkeiten dreierlei: einen goldenen Ring, ein goldenes Spinnrädchen und ein goldenes Haspelchen; die drei Kleider von Sonne, Mond und Sterne tat sie in eine Nußschale, zog den Mantel von allerlei Rauchwerk an und machte sich Gesicht und Hände mit Ruß schwarz. Dann befahl sie sich Gott und ging fort und ging die ganze Nacht, bis sie in einen großen Wald kam. Und weil sie müde war, setzte sie sich in einen hohlen Baum und schlief ein.

Die Sonne ging auf, und sie schlief fort und schlief noch immer, als es schon hoher Tag war. Da trug es sich zu, daß der König, dem dieser Wald gehörte, darin jagte. Als seine Hunde zu dem Baum kamen, schnupperten sie, liefen rings herum und bellten. Sprach der König zu den Jägern: »Seht nach, was dort für ein Wild sich versteckt hat.« Die Jäger folgten dem Befehl, und als sie wiederkamen, sprachen sie: »In dem hohlen Baum liegt ein wunderliches Tier, wie wir noch niemals eins gesehen haben; an seiner Haut ist tausenderlei Pelz, es liegt aber und schläft.« Sprach der König »Seht zu, ob ihr's lebendig fangen könnt, dann bindet's auf den Wagen und nehmt's mit.« Als die Jäger das Mädchen anfaßten, erwachte es voll Schrecken und rief ihnen zu »Ich bin ein armes Kind, von Vater und Mutter verlassen, erbarmt euch mein und nehmt mich mit!« Da sprachen sie: *Allerleirauh*, du bist gut für die Küche, komm nur mit, da kannst du die Asche zusammenkehren.« Also setzten sie es auf den Wagen und fuhren heim in das königliche Schloß. Dort wiesen sie ihm ein Ställchen an unter der Treppe, wo kein Tageslicht hinkam, und sagten: »Rauhtierchen, da kannst du wohnen und schlafen.« Dann ward es in die Küche geschickt, da trug es Holz und Wasser, schürte das Feuer, rupfte das Federvieh, belas das Gemüs', kehrte die Asche und tat alle schlechte Arbeit.

Da lebte Allerleirauh lange Zeit recht armselig. Ach, du schöne Königstochter, wie soll's mit dir noch werden! Es geschah aber einmal, daß ein Fest im Schloß gefeiert ward, da sprach sie zum Koch: »Darf ich ein wenig hinaufgehen und zusehen? Ich will mich außen vor die Türe stellen.« Antwortete der Koch: »Ja, geh nur hin, aber in einer halben Stunde mußt du wieder hier sein und die Asche zusammentragen!« Da nahm sie ihr Öllämpchen, ging in ihr Ställchen, zog den Pelzrock aus und wusch sich den Ruß von dem Gesicht und den Händen ab, so daß ihre volle Schönheit wieder an den Tag kam. Dann machte sie die Nuß auf und holte ihr Kleid hervor, das wie die Sonne glänzte. Und wie das geschehen war, ging sie hinauf zum Fest, und alle traten ihr aus dem Weg, denn niemand kannte sie, und meinten nicht anders, als daß es eine Königstochter wäre. Der König aber kam ihr entgegen, reichte ihr die Hand und tanzte mit ihr und dachte in seinem Herzen: So schön haben meine Augen noch keine gesehen. Als der Tanz zu Ende war, verneigte sie sich, und wie sich der König umsah, war sie verschwunden, und niemand wußte wohin. Die Wächter, die vor dem Schlosse standen, wurden gerufen und ausgefragt, aber niemand hatte sie erblickt.

Sie war aber in ihr Ställchen gelaufen, hatte geschwind ihr Kleid ausgezogen, Gesicht und Hände schwarz gemacht und den Pelzmantel umgetan und war wieder Allerleirauh. Als sie nun in die Küche kam und an ihre Arbeit gehen und die Asche zusammenkehren wollte, sprach der Koch: »Laß das gut sein bis morgen und koche mir da die Suppe für den König, ich will auch einmal ein bißchen oben zugucken, aber laß mir kein Haar hineinfallen, sonst kriegst du in Zukunft nichts mehr zu essen!« Da ging der Koch fort, und Allerleirauh kochte die Suppe für den König und kochte eine Brotsuppe, so gut es konnte, und wie sie fertig war, holte es in dem Ställchen seinen goldenen Ring und legte ihn in die Schüssel, in welche die Suppe angerichtet ward. Als der Tanz zu Ende war, ließ sich der König die Suppe bringen und aß sie, und sie schmeckte ihm so gut, daß er meinte, niemals eine bessere Suppe gegessen zu haben. Wie er aber auf den Grund kam, sah er da einen goldenen Ring liegen und konnte nicht begreifen, wie er dahingeraten war. Da befahl er, der Koch sollte vor ihn kommen. Der Koch erschrak, wie er den Befehl hörte, und sprach zum Allerleirauh: »Gewiß hast du ein Haar in die Suppe fallen lassen; wenn's wahr ist, so kriegst du Schläge!« Als er vor den König kam, fragte dieser, wer die Suppe gekocht hätte. Antwortete der Koch: »Ich habe sie gekocht.« Der König sprach: »Das ist nicht wahr, denn sie war auf andere Art und viel besser gekocht als sonst.« Antwortete er: »Ich muß gestehen, daß ich sie nicht gekocht habe, sondern das Rauhtierchen.« Sprach der König: »Geh und laß es heraufkommen.«

Als Allerleirauh kam, fragte der König: »Wer bist du?« »Ich bin ein armes Kind, das keinen Vater und Mutter mehr hat.« Fragte er weiter: »Wozu bist du in meinem Schloß?« Antwortete es: »Ich bin zu nichts gut, als daß mir die Stiefel um den Kopf geworfen werden.« Fragte er weiter: »Wo hast du den Ring her, der in der Suppe war?« Antwortete es: »Von dem Ring weiß ich nichts.« Also konnte der König nichts erfahren und mußte es wieder fortschicken.

Über eine Zeit war wieder ein Fest, da bat Allerleirauh den Koch wie vorigesmal um Erlaubnis, zusehen zu dürfen. Antwortete er: »Ja, aber komm in einer halben Stunde wieder und koch dem König die Brotsuppe, die er so gerne ißt.« Da lief es in sein Ställchen, wusch sich geschwind und nahm aus der Nuß das Kleid, das so silbern war wie der Mond, und tat es an. Da ging sie hinauf und glich einer Königstochter, und der König trat ihr entgegen und freute sich, daß er sie wiedersah, und weil eben der Tanz anhub, so tanzten sie zusammen. Als aber der Tanz zu Ende war, verschwand sie wieder so schnell, daß der König nicht bemerken konnte, wo sie hinging. Sie sprang aber in ihr Ställchen und machte sich wieder zum Rauhtierchen und ging in die Küche, die Brotsuppe zu kochen. Als der Koch oben war, holte es das goldene Spinnrad und tat es in die Schüssel, so daß die Suppe darüber angerichtet wurde. Danach ward sie dem König gebracht, der aß sie und sie schmeckte ihm so gut wie das vorigemal, und ließ den Koch kommen, der mußte auch diesmal gestehen, daß Allerleirauh die Suppe gekocht hätte. Allerleirauh kam da wieder vor den König, aber sie antwortete, daß sie nur dazu wäre, daß ihr die Stiefel an den Kopf geworfen würden und daß sie von dem goldenen Spinnrädchen gar nichts wüßte

Als der König zum drittenmal ein Fest anstellte, da ging es nicht anders als die vorigen Male. Der Koch sprach zwar: »Du bist eine Hexe, Rauhtierchen, und tust immer was in die Suppe, davon sie so gut wird und dem König besser schmeckt als was ich koche.« Doch weil sie so bat, so ließ er es auf die bestimmte Zeit hingehen. Nun zog es ein Kleid an, das wie die Sterne glänzte, und trat damit in den Saal. Der König tanzte wieder mit der schönen Jungfrau und meinte, daß sie noch niemals so schön gewesen wäre. Und während er tanzte, steckte er ihr, ohne daß sie es merkte, einen goldenen Ring an den Finger und hatte befohlen, daß der Tanz recht lang währen sollte. Wie er zu Ende war, wollte er sie an den Händen festhalten, aber sie riß sich los und sprang so geschwind unter die Leute, daß sie vor seinen Augen verschwand. Sie lief, was sie konnte, in ihr Ställchen unter der Treppe, weil sie aber zu lange und über eine halbe Stunde geblieben war, so konnte sie das schöne Kleid nicht ausziehen, sondern warf nur den Mantel von Pelz darüber, und in der Eile machte sie sich auch nicht ganz rußig, sondern ein Finger blieb weiß.

Allerleirauh lief nun in die Küche kochte dem König die Brotsuppe und legte, wie der Koch fort war, den goldenen Haspel hinein. Der König, als er den Haspel auf dem Grunde fand, ließ Allerleirauh rufen, da erblickte er den weißen Finger und sah den Ring, den er im Tanze ihr angesteckt hatte. Da ergriff er sie an der Hand und hielt sie fest, und als sie sich losmachen und fortspringen wollte, tat sich der Pelzmantel ein wenig auf, und das Sternenkleid schimmerte hervor. Der König faßte den Mantel und riß ihn ab. Da kamen die goldenen Haare hervor, und sie stand da in voller Pracht und konnte sich nicht länger verbergen. Und als sie Ruß und Asche aus ihrem Gesicht gewischt hatte, da war sie schöner, als man noch jemand auf Erden gesehen hat. Der König aber sprach: »Du bist meine liebe Braut, und wir scheiden nimmermehr voneinander!« Darauf ward die Hochzeit gefeiert, und sie lebten vergnügt bis zu ihrem Tod.

- Keine Parallelisierung
- Informationen werden “vergessen”

Transformer 2017

Das “T” in ChatGPT

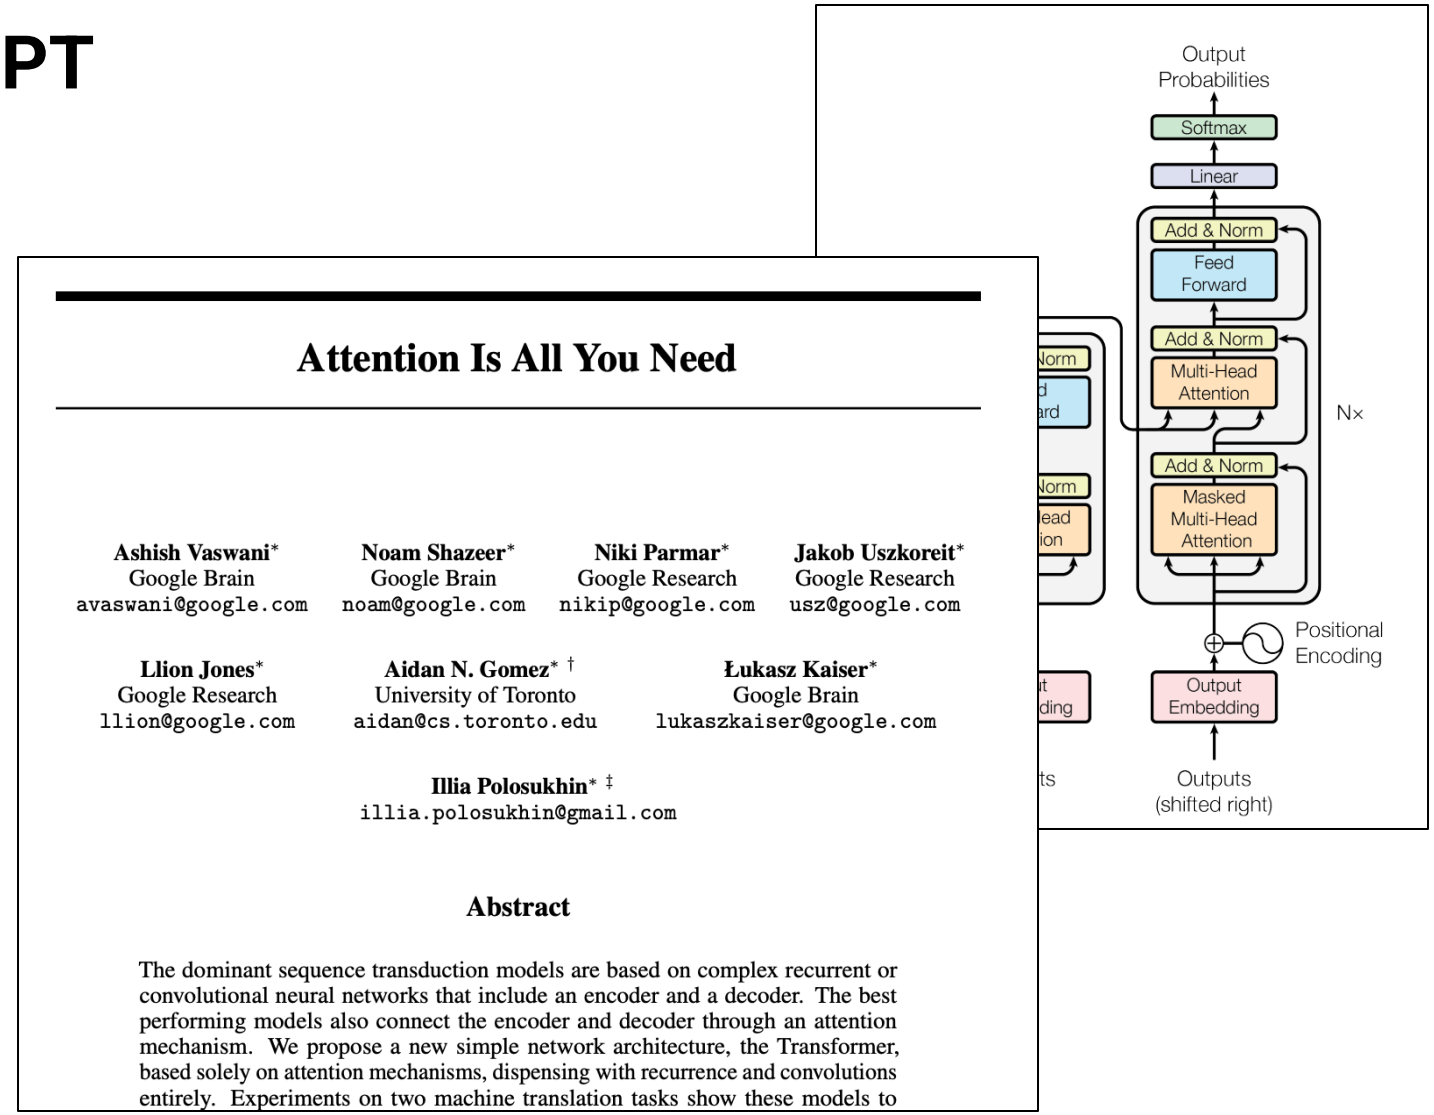

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to

Transformer Architecture

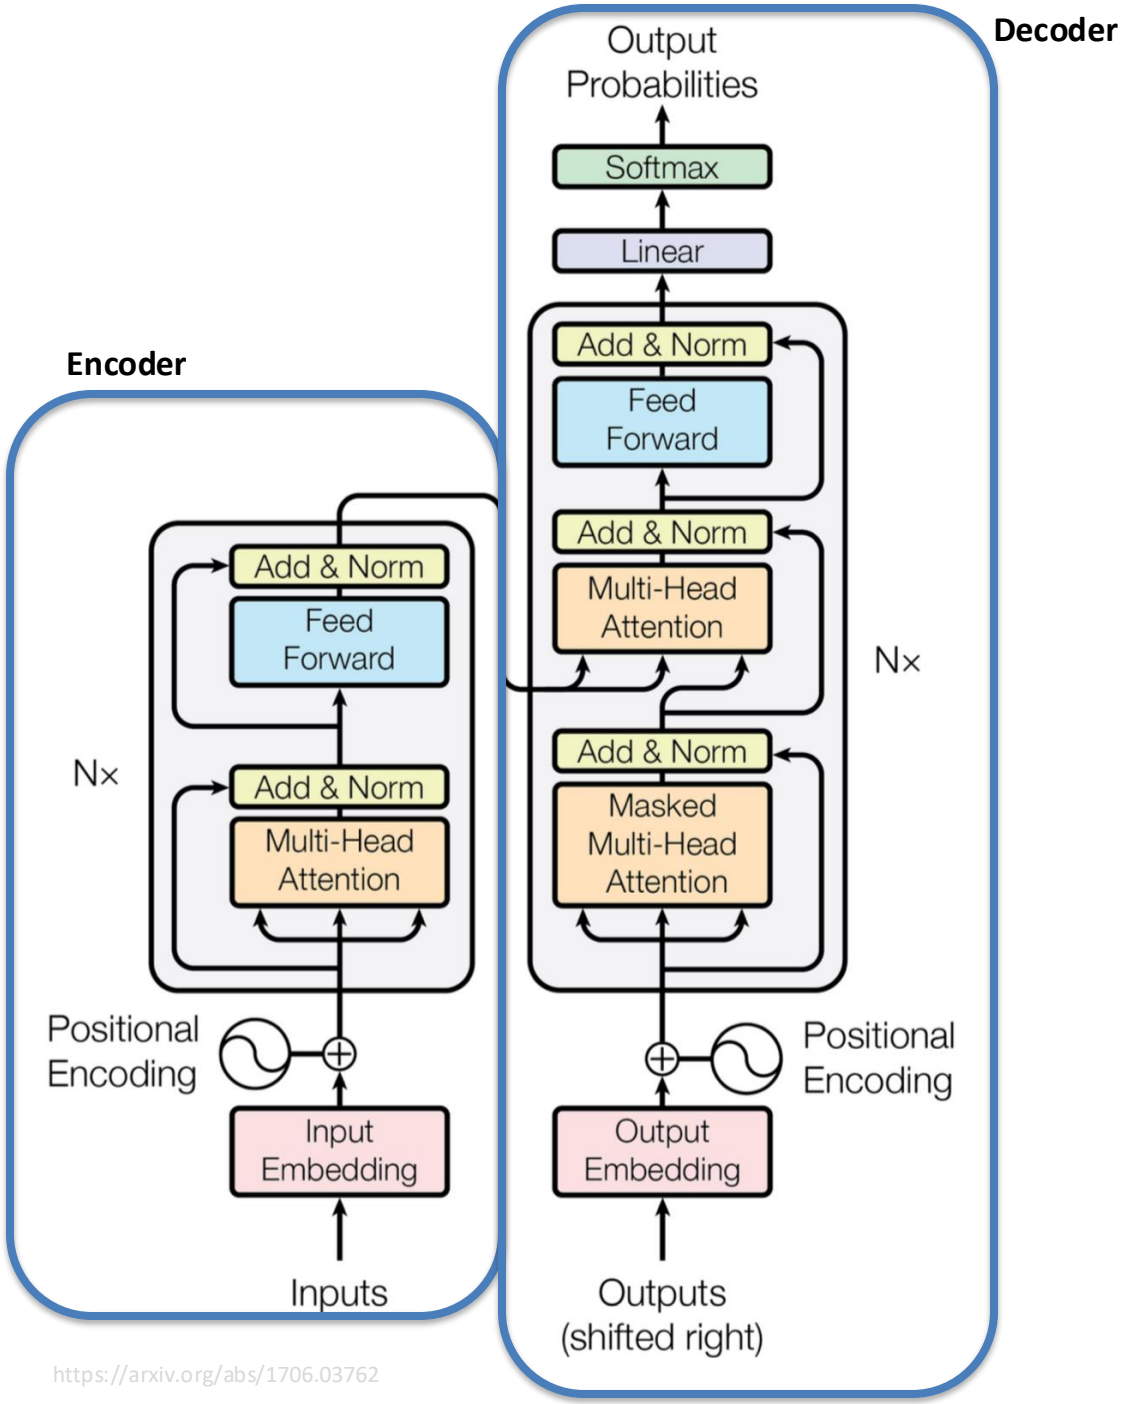

https://arxiv.org/abs/1706.03762

Videos

Wortvektoren (Embeddings)

Sushi

$$\begin{bmatrix} 5.2 \\ 1.3 \\ 0.4 \\ \vdots \\ 2.9 \end{bmatrix} E(Sushi)$$

Japan

$$\begin{bmatrix} 9.2 \\ 1.1 \\ 0.3 \\ \vdots \\ 1.1 \end{bmatrix} E(Japan)$$

Deutschland

$$\begin{bmatrix} 1.2 \\ 3.3 \\ 2.4 \\ \vdots \\ 8.1 \end{bmatrix} E(Deutschland)$$

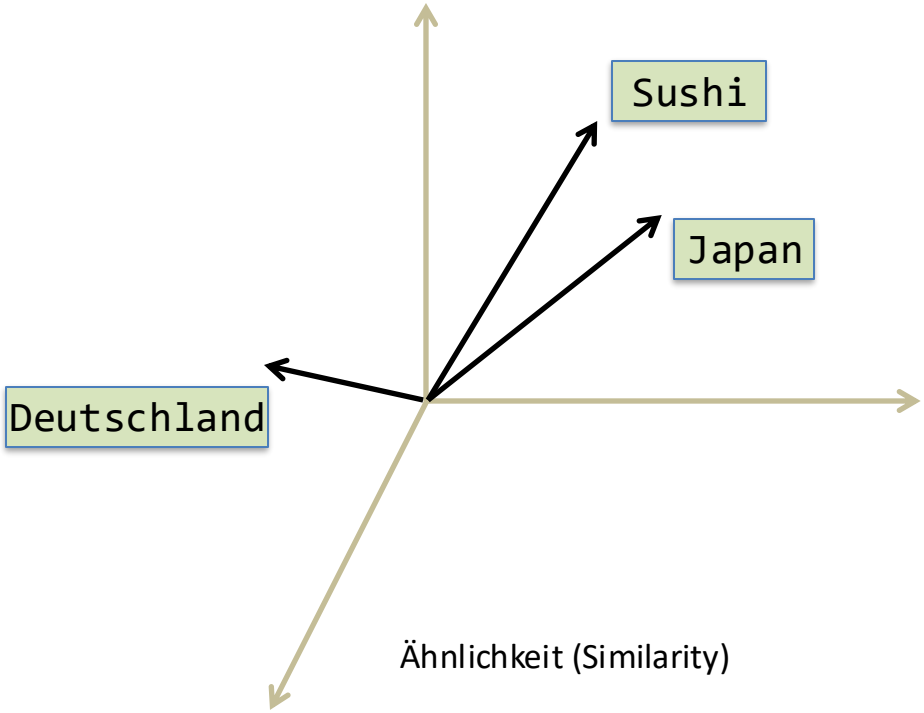

Ähnlichkeit (Similarity)

$$S = v \cdot w = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} \cdot \begin{bmatrix} w_1 \\ \vdots \\ w_n \end{bmatrix}$$

Wortvektoren (Embeddings)

Sushi − Japan + Deutschland = Bratwurst

$$\begin{bmatrix} 5.2 \\ 1.3 \\ 0.4 \\ \vdots \\ 2.9 \end{bmatrix} E(Sushi) \qquad \begin{bmatrix} 9.2 \\ 1.1 \\ 0.3 \\ \vdots \\ 1.1 \end{bmatrix} E(Japan) \qquad \begin{bmatrix} 1.2 \\ 3.3 \\ 2.4 \\ \vdots \\ 8.1 \end{bmatrix} E(Deutschland)$$

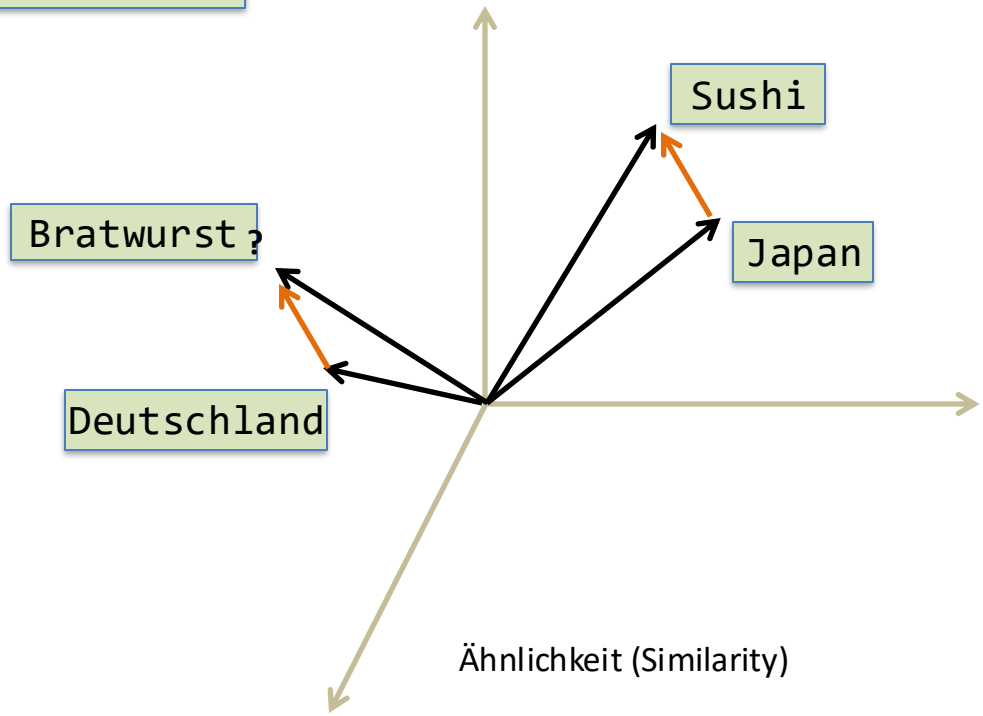

kälter − kalt + schnell = schneller

Onkel − Mann + Frau = Tante

Einstein − Wissenschaftler + Fußballspieler = Messi

$$S = v \cdot w = \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} \cdot \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}$$

https://vectors.nlpl.eu

Transformer Use Cases

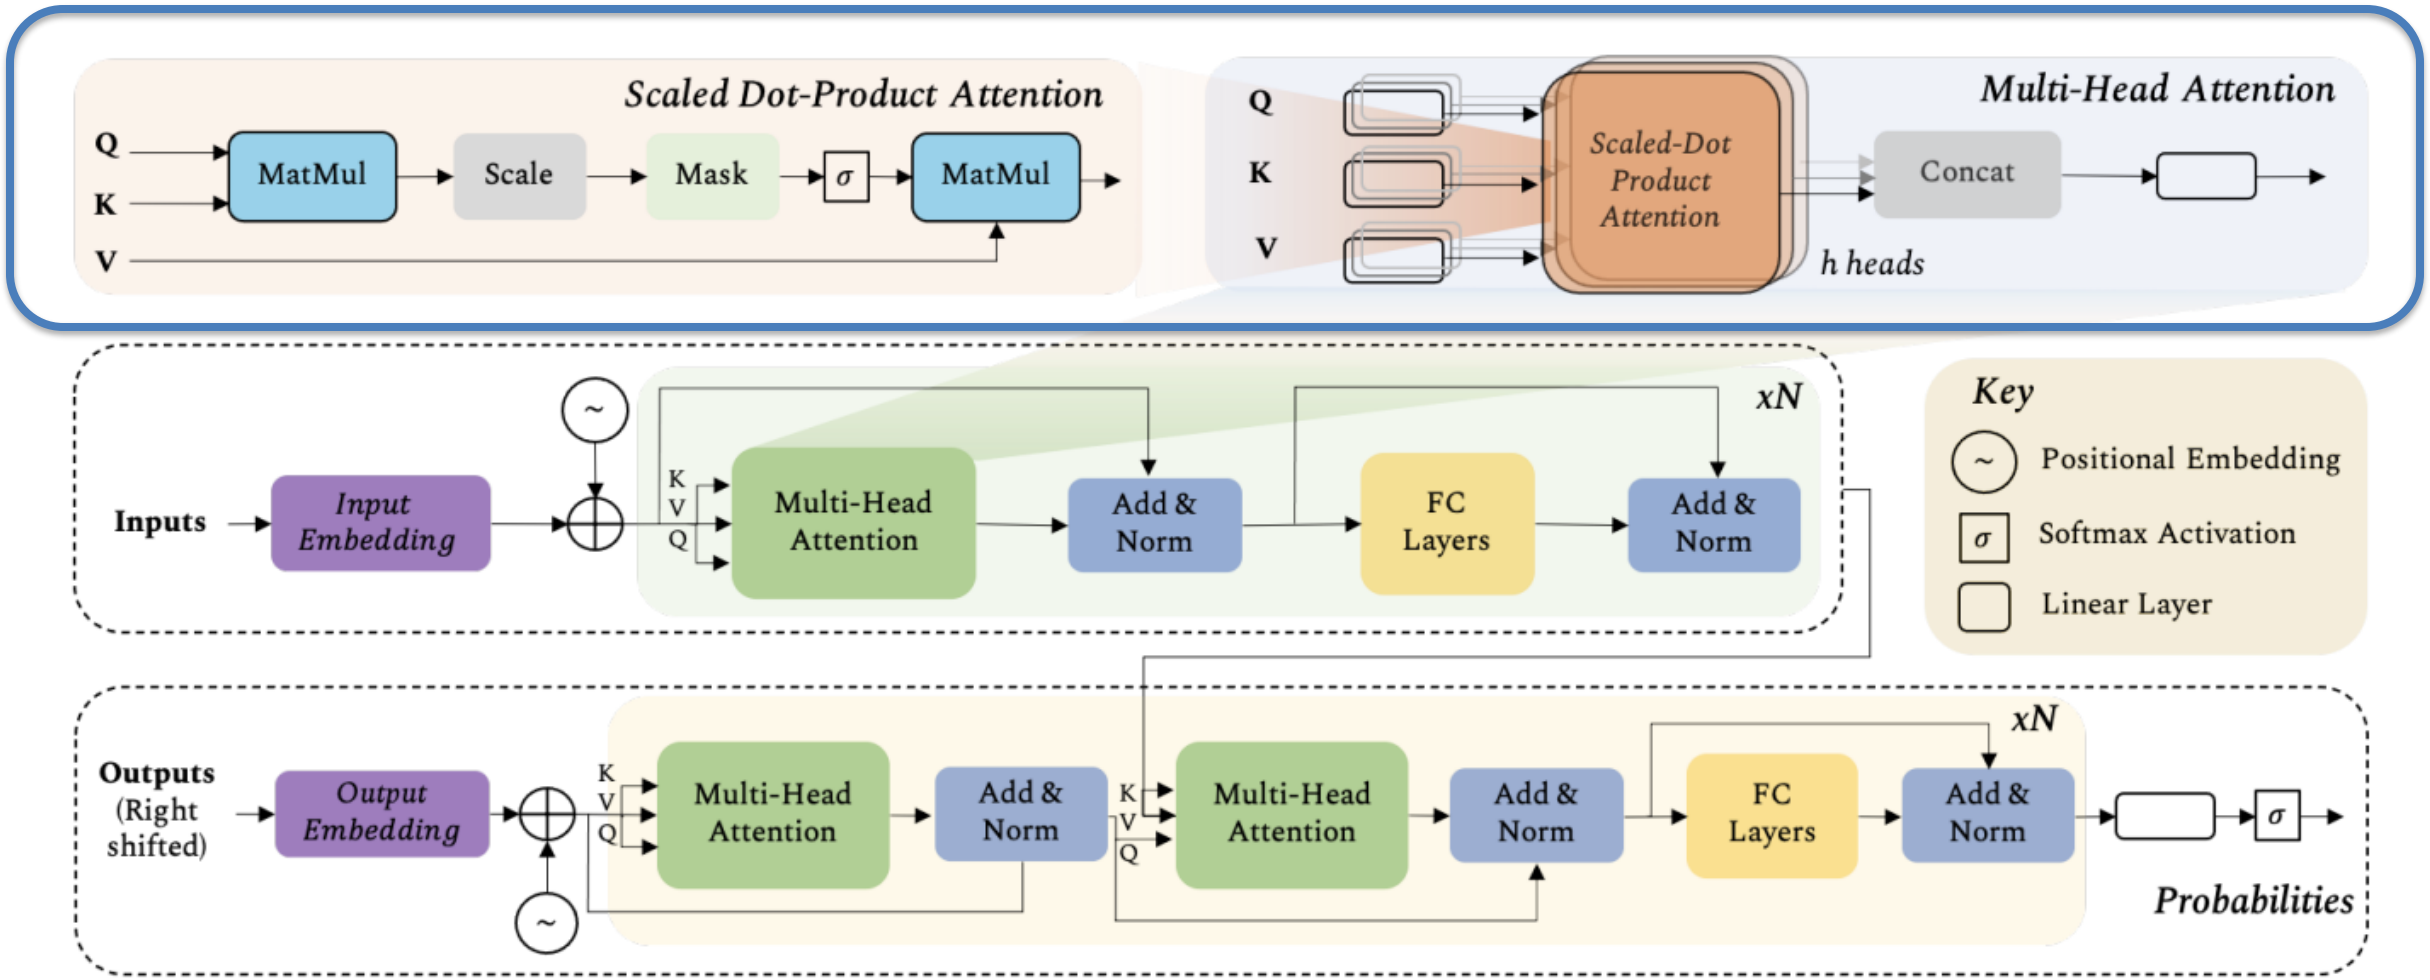

Attention Mechanismus (Aufmerksamkeit)

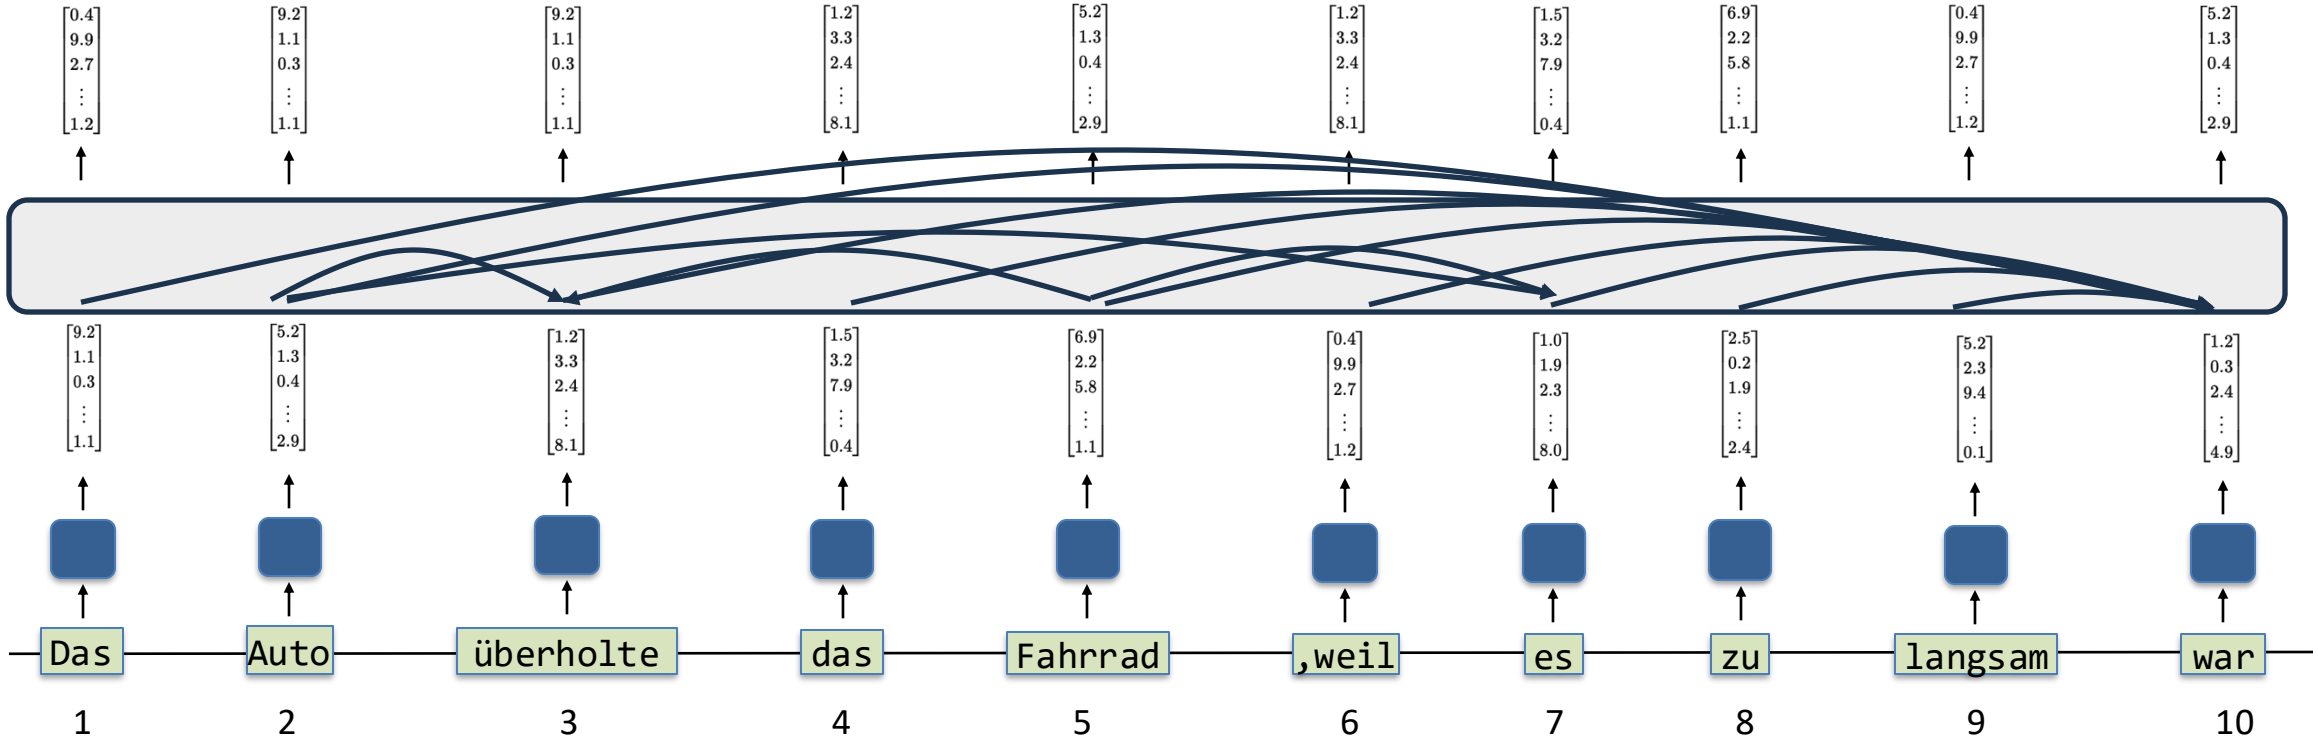

Attention Mechanismus (Aufmerksamkeit)

Query (Q): *”Das will ich wissen.”*
Key (K): *“Darüber weiß ich etwas.”*
Value (V): *“Meine Informationen.”*

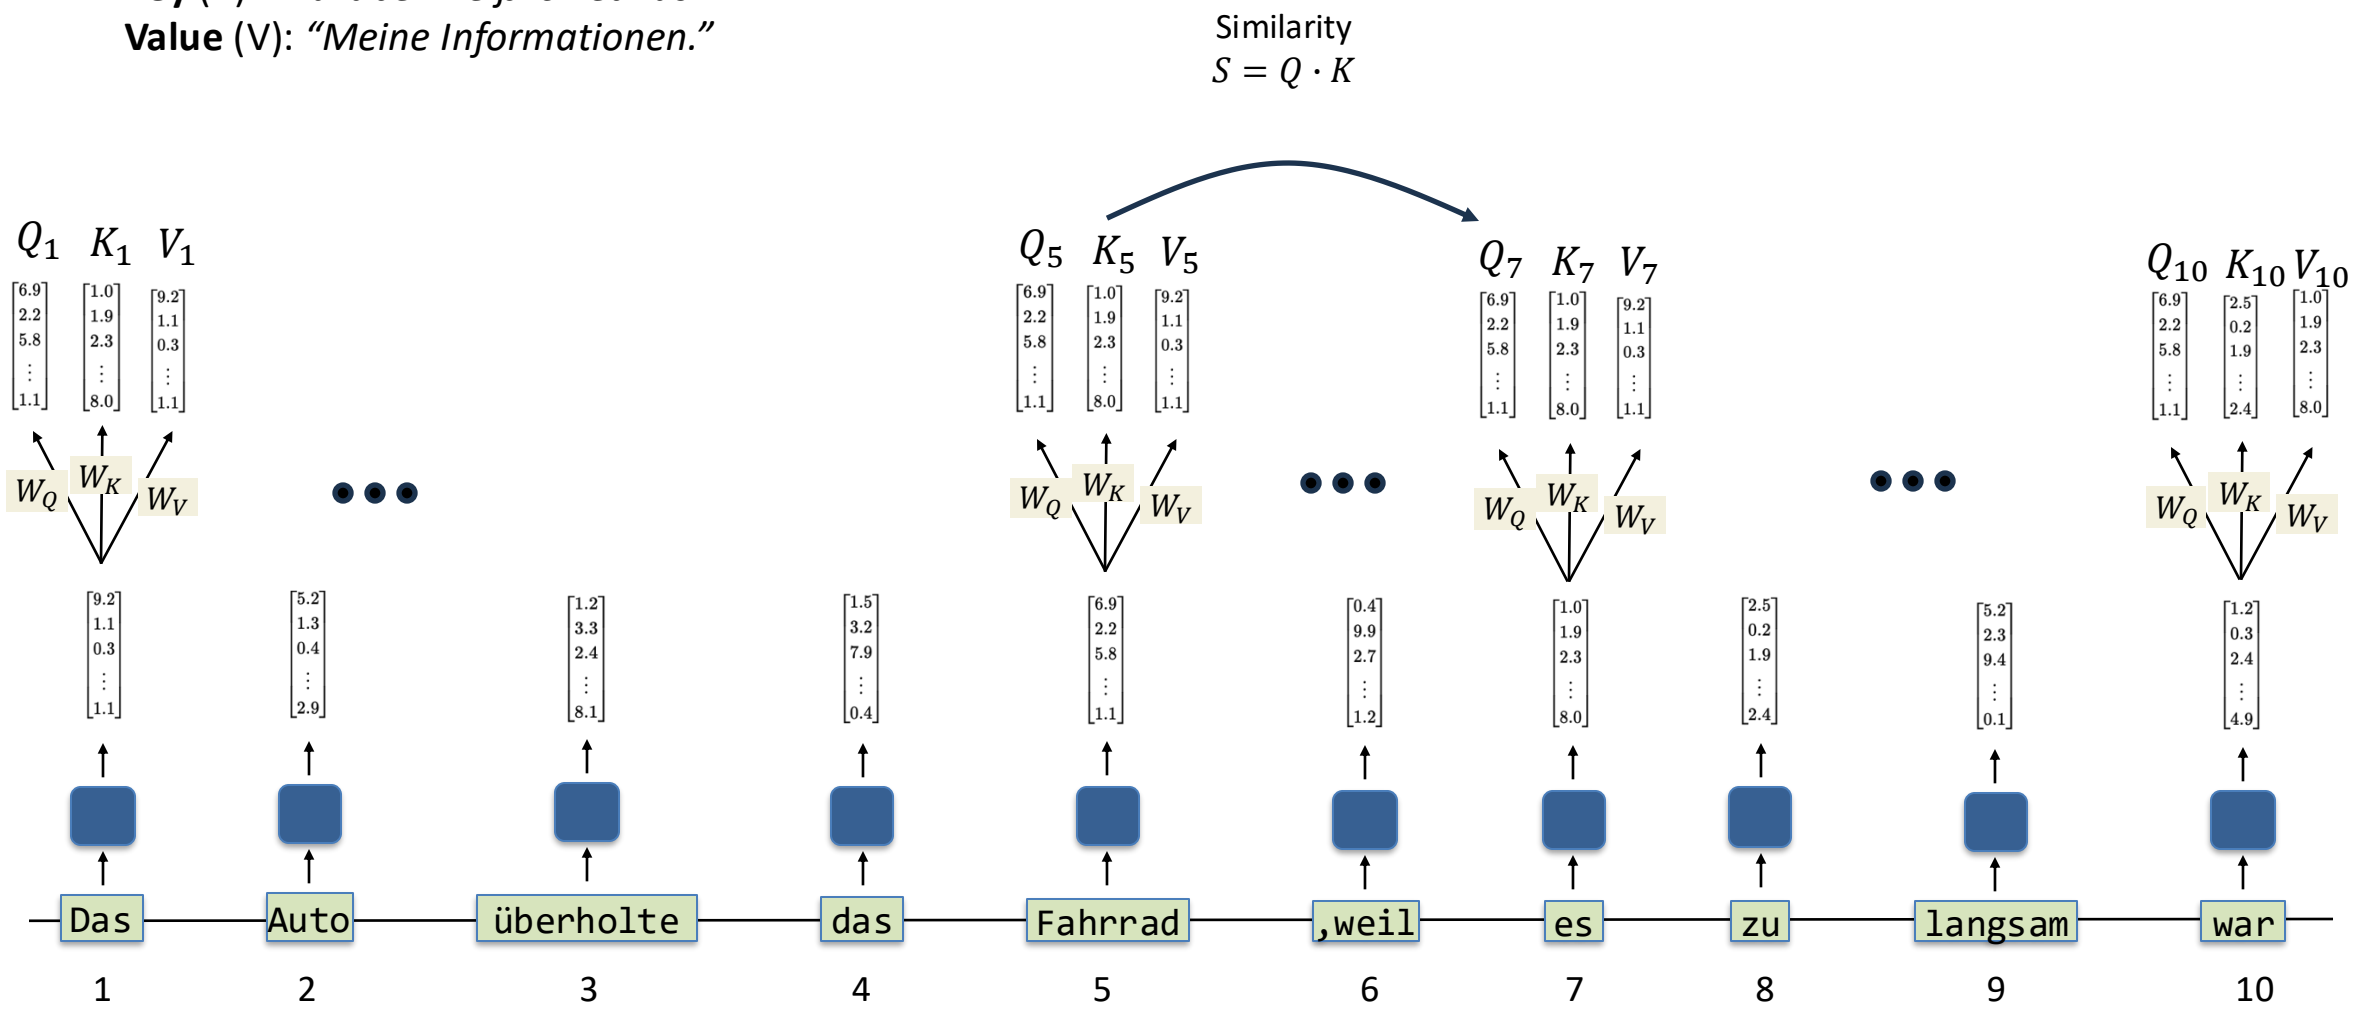

Attention Mechanismus

Query (Q): *”Das will ich wissen.”*
Key (K): *“Darüber weiß ich etwas.”*
Value (V): *“Meine Informationen.”*

		Das	Auto	überholte	das	Fahrrad	,weil	es		
		Q_1	Q_2	Q_3	Q_4	Q_5	Q_6	Q_7	Q_8	
Das	K_1			$K_1 \cdot Q_3$						$\rightarrow 0.01 \cdot V_1$
Auto	K_2			$K_2 \cdot Q_3$						$\rightarrow 0.31 \cdot V_2$
überholte	K_3			$K_3 \cdot Q_3$						$\rightarrow 0.00 \cdot V_3$
das	K_4			$K_4 \cdot Q_3$						$\rightarrow 0.02 \cdot V_4$
Fahrrad	K_5			$K_5 \cdot Q_3$						$\rightarrow 0.32 \cdot V_5$
,weil	K_6			$K_6 \cdot Q_3$						$\rightarrow 0.01 \cdot V_6$
es	K_7			$K_7 \cdot Q_3$						$\rightarrow 0.28 \cdot V_7$
	K_8									

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

$+ \quad \vdots$

$\rightarrow$ Update für Wortvektor

überholte

Transformer

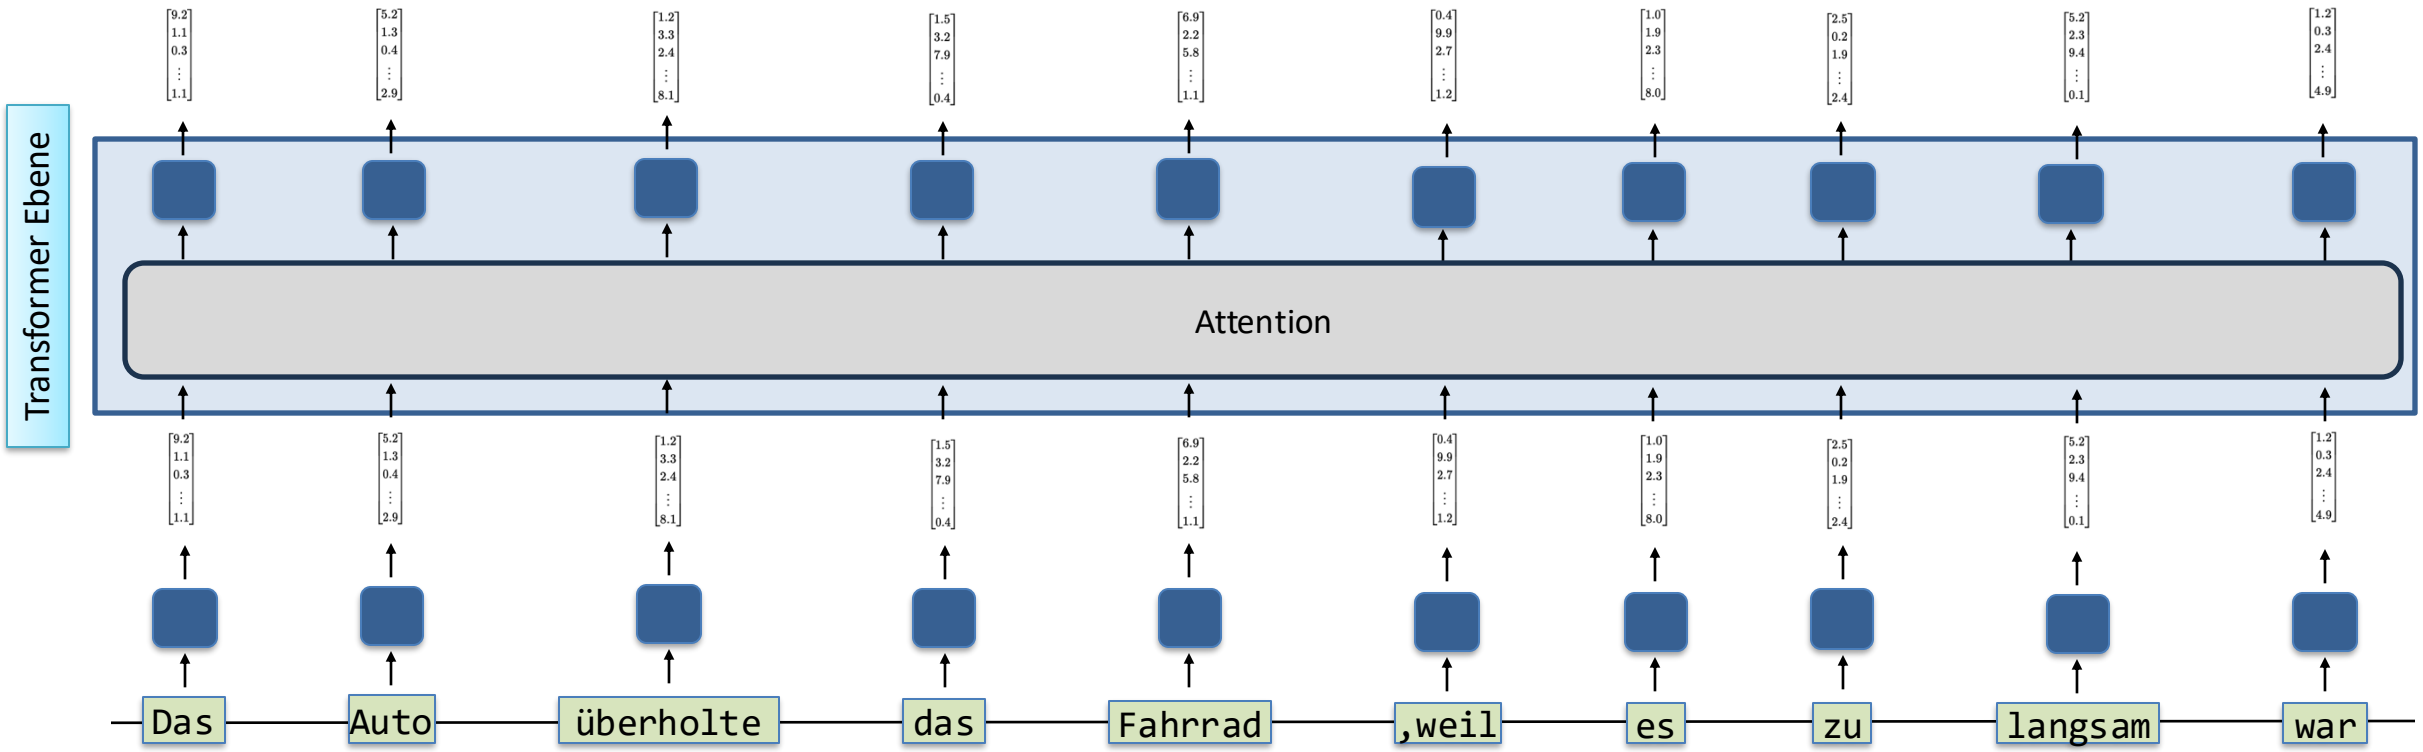

Transformer

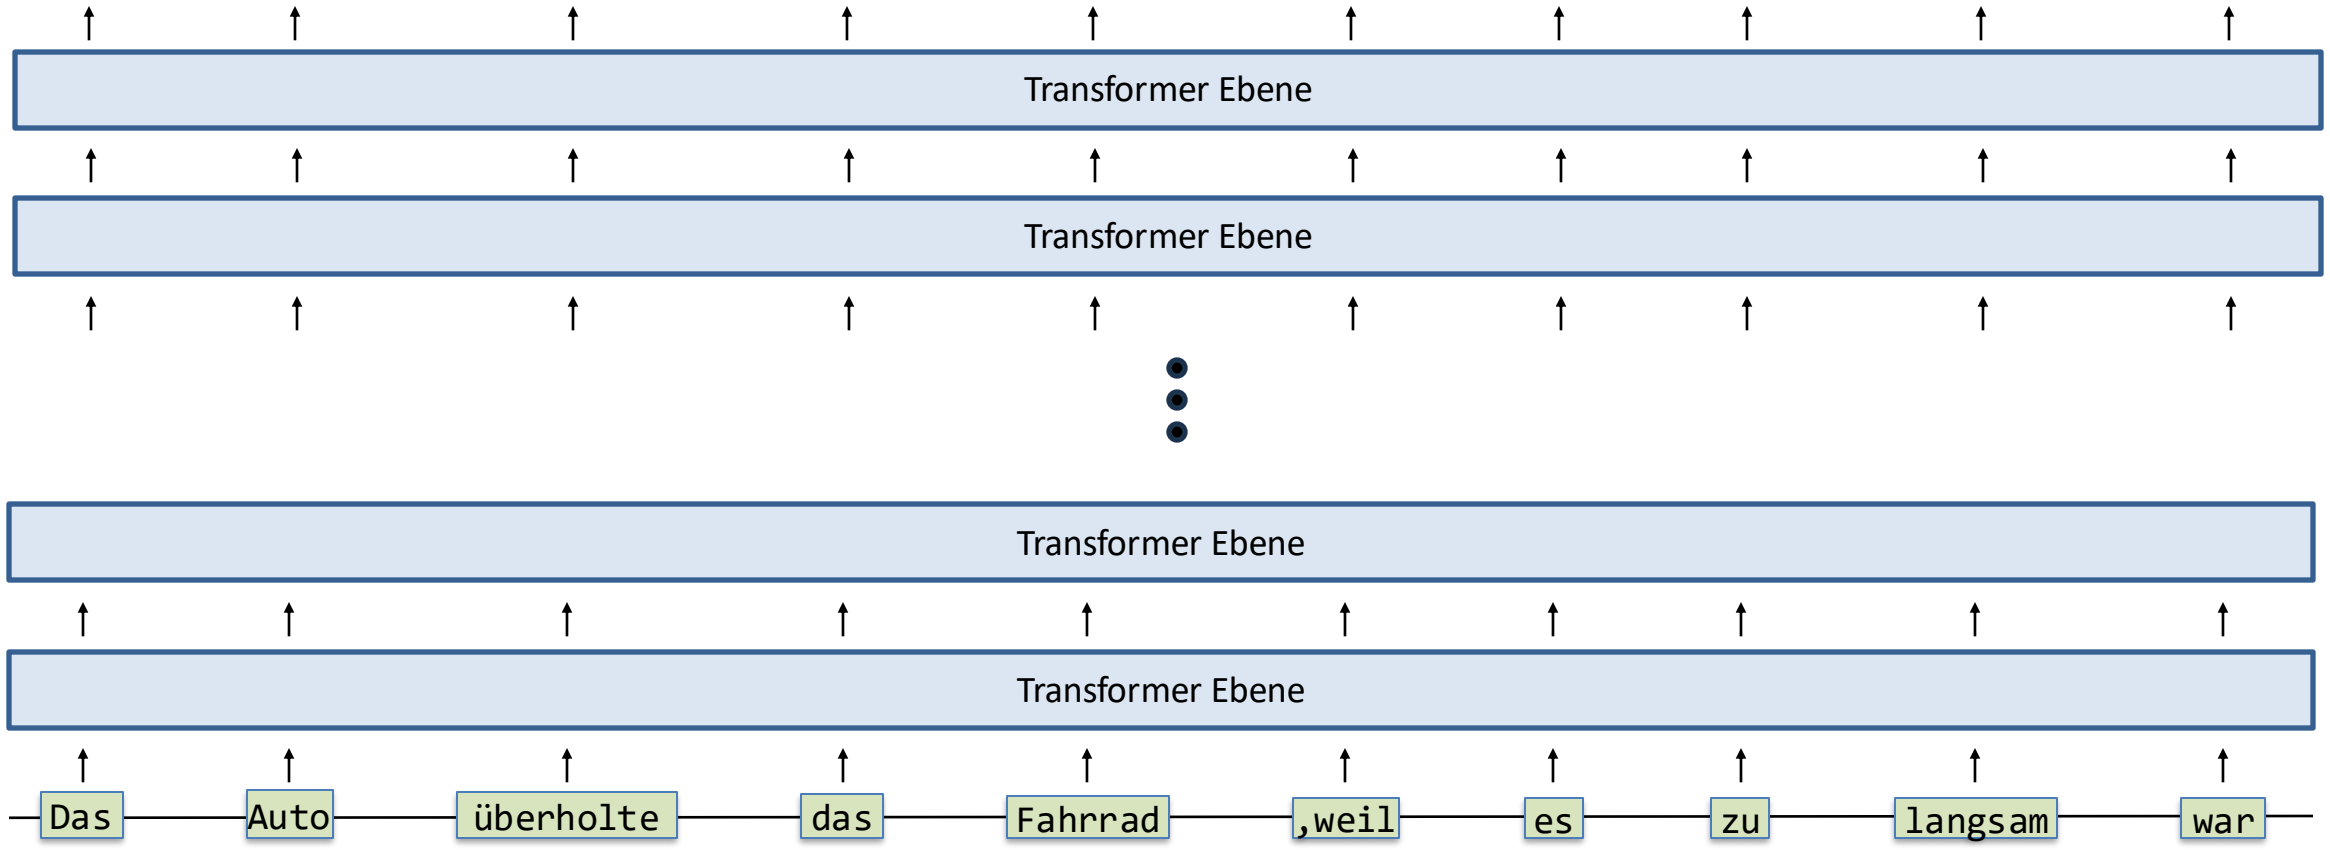

Warum funktioniert das so gut?

Transformer

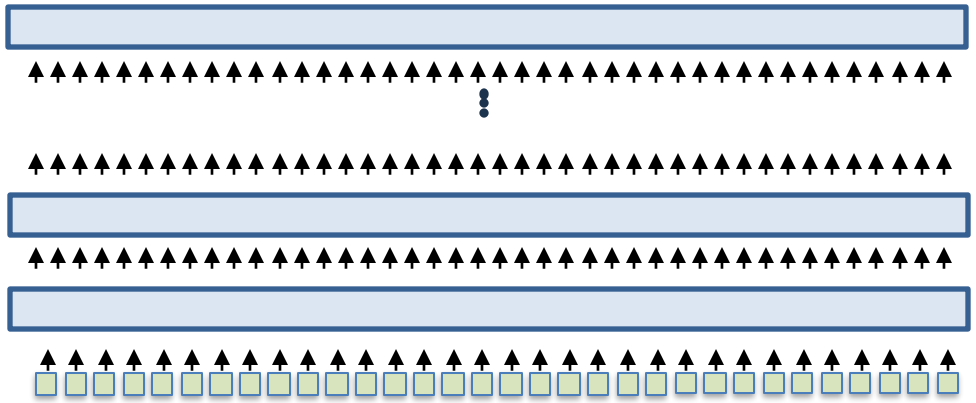

RNN

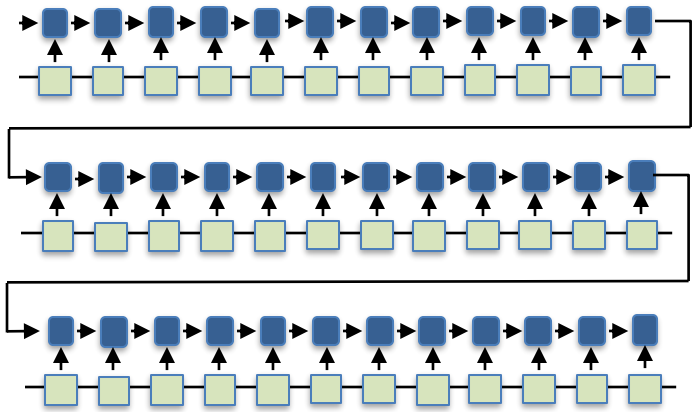

- Parallelisierung!
  - GPUs
  - Je mehr Daten desto besser
- Attention verhindert vergessen

Self-Attention

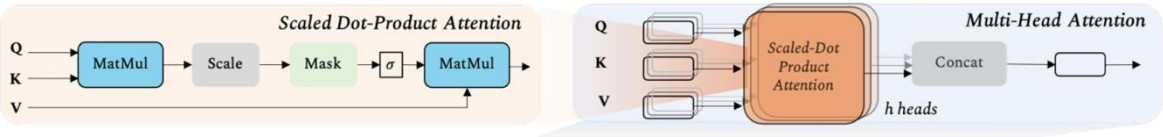

- **Query (Q):** Represents the current word or token's "**query**" about other words in the sentence. **"How relevant are other words in the context of my meaning?"**

- **Key (K):** Represents the "**keys**" associated with each word in the sentence. Attribute for each word that can be matched against queries. Key matrix is used to compare against the Query matrix to measure the relevance or compatibility between words

- **Value (V):** Represents the actual content of each word in the sentence

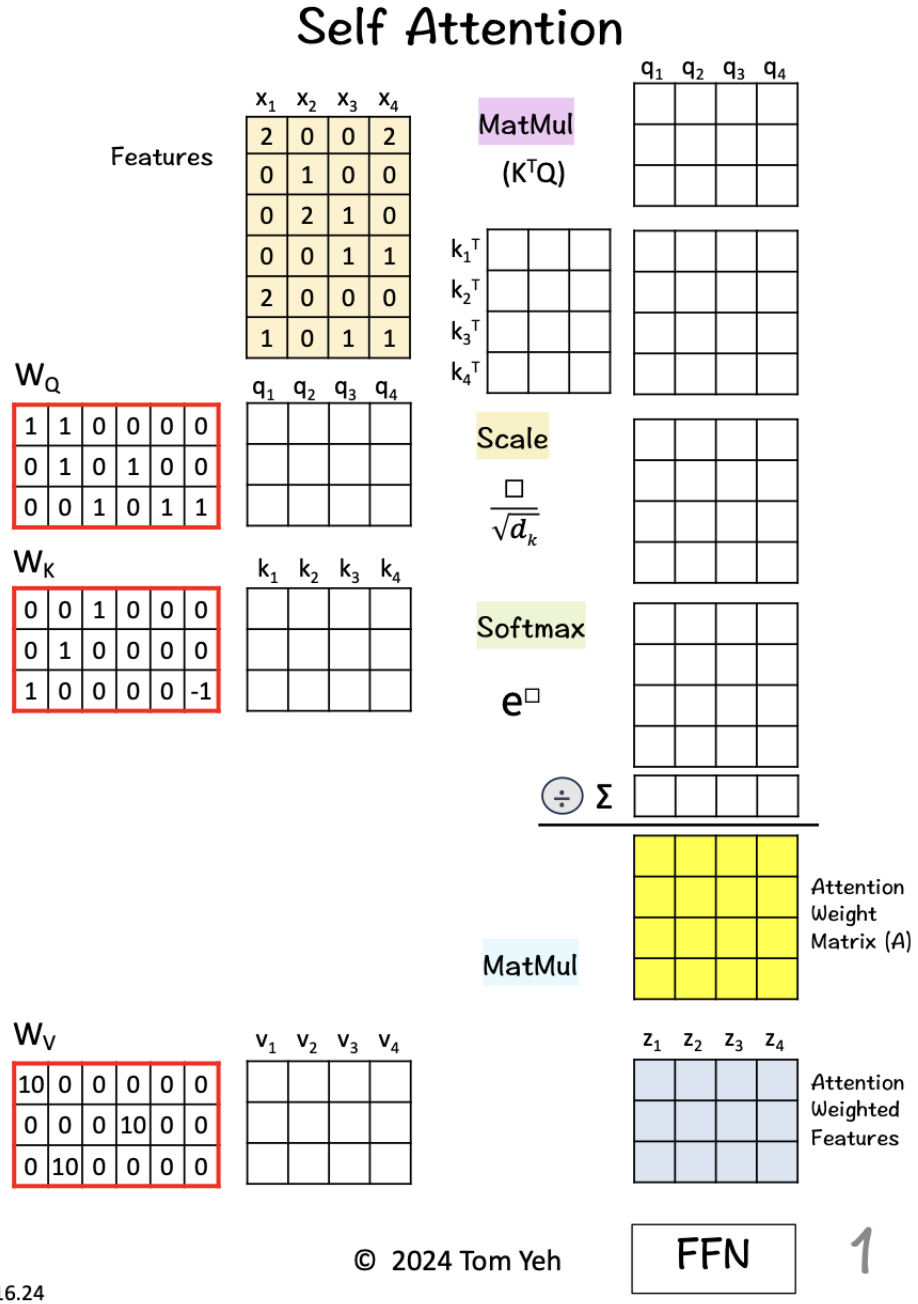

© 2024 Tom Yeh

Self-Attention - Example

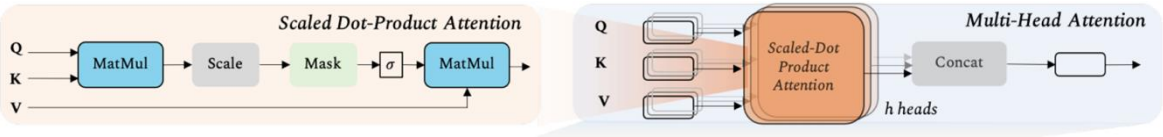

- "The cat sat on the mat."
- **Query (Q)**: "cat" asking, "How important is each word in the sentence to understand me ('cat') better?"
- **Key (K)**: Each word ("cat" "sat" "on" "the" "mat") has a key, which acts as an attribute that can respond to any query.
- **Value (V)**: Each word has a value that contains its actual meaning or representation.

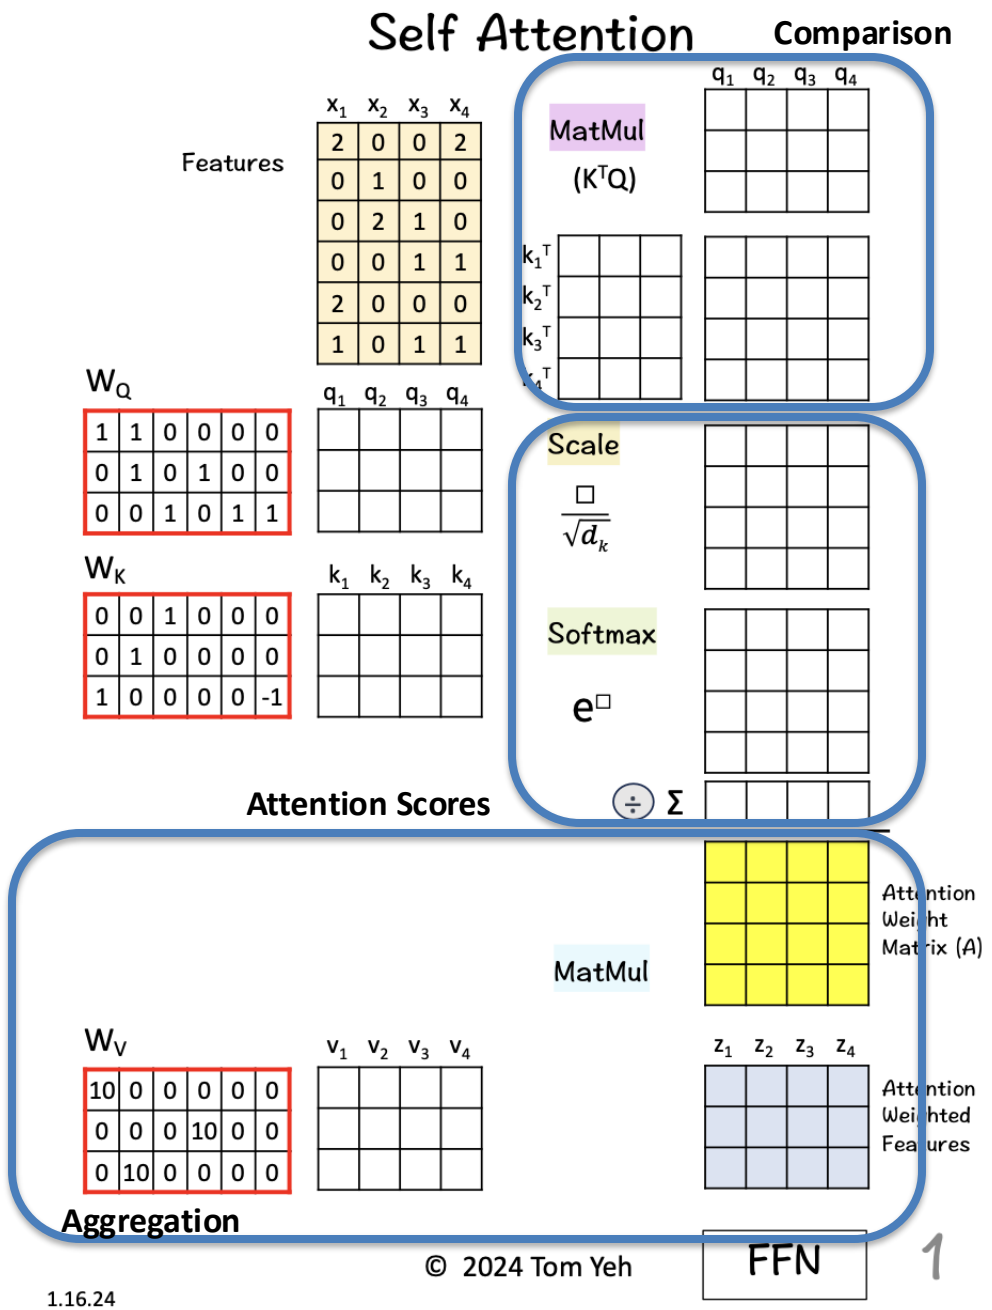

© 2024 Tom Yeh

Zusammenfassung

Transformer sind Neuronale Netze und Grundlage von LLMs

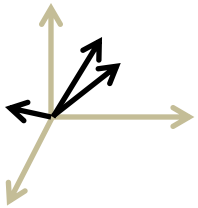

Transformer benutzen Embeddings (z.B. Wortvektoren)

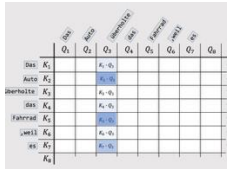

Attention tauscht Informationen zwischen Wortvektoren aus (Query, Key, Value)

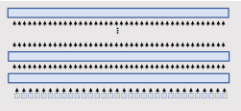

Erlaubt hohe Parallelisierung

V Wieviele E's kommen in dem Wort Erdbeere vor?

In dem Wort "Erdbeere" kommen 3 E's vor:

- Das erste E am Anfang von "Erdbeere"
- Das zweite E nach dem B in "Erdbeere"
- Das dritte E am Ende des Wortes "Erdbeere"

Transformer Use Cases

Task	Method	**Design Highlights** (focus on differences with the standard form)	Input Data Type	Label Type	Loss
Image Classification	ViT [11]	Directly adopted NLP Transformer Encoder for images, Mechanism to linearly embed image patches with positional embedding suitable for the Encoder.	2D Image	Class labels	Cross-entropy
	DeiT [12]	Transformer as s student while CNN as a teacher, Distillation tokens to produce estimated labels from teacher, Attention between class and distillation tokens.	2D Image	Class labels	Cross-entropy, Distillation loss based on KL-divergence
	CLIP [195]	Jointly train image and text encoders on image-text pairs, to maximize similarity of valid pairs and minimize otherwise	2D Images & texts	Image-text pairs	Symmetric cross-entropy
Object Detection	DETR [13]	Linear projection layer to reduce CNN feature dimension, Spatial positional embedding added to each multi-head self-attention layer of both encoder and decoder. Object queries (output positional encoding) added to each multi-head self-attention layer of decoder.	2D Image	Class labels	Hungarian loss based on bipartite matching between predicted and ground truths
	D-DETR [14]	Deformable Transformer consists of deformable attention layers to introduce sparse priors in Transformers, Multi-scale attention module.	2D Image	Class labels	Hungarian loss
Low Shot Learning	CT [25]	Self-supervised pretraining, Query-aligned class prototypes that provide spatial correspondence between the support-set images and query image.	2D Image	Pretraining without labels and few-shot learning with Class labels	Normalized Cross-entropy
Image Colorization	ColTran [24]	Conditional Row/column multi-head attention layers, Progressive multi-scale colorization scheme.	2D Image	2D Image	Negative log-likelihood of the images
Action Recognition	ST-TR [216]	Spatial and Temporal self-attention to operates on graph data such as joints in skeletons.	Skeleton	Action Classes	Cross-entropy
Super-resolution	TTSR [16]	Texture enhancing Transformer module, Relevance embeddings to compute the relevance between the low-resolution and reference image.	2D Image	2D Image	Reconstruction loss, Perceptual loss defined on pretrained VGG19 features.
Multi-Model Learning	Oscar [44]	Transformer layer to jointly process triplet representation of image-text [words, tags, features], Masked tokens to represent text data.	2D Image	Captions, Class labels, Object tags	Negative log-likelihood of masked tokens, Contrastive binary cross-entropy
3D Classification/Segmentation	PT [230]	Point Transformer block, Transition down block to reduce cardinality of the point set, Transition up for dense prediction tasks.	CAD models, 3D object part segmentation	Object and shape categories	Cross-entropy
3D Mesh Reconstruction	METRO [45]	Progressive dimensionality reduction across Transformer layers, Positional Encoding with 3D joint and 3D vertex coordinates, Masked vertex/joint modeling.	2D Image	3D Mesh + Human Pose	L_1 loss on mesh vertices and joints in 3D and 2D projection.
Vision and Language Navigation	Chen *et al.* [194]	Uni-modal encoders on language and map inputs followed by a cross-modal transformer, Trajectory position encodings in the map encoder.	Instruction text + RGBD panorama + Topological Environment Map	Navigation Plan	Cross-entropy over nodes and `[stop]` action
Referring Image Segmentation	CMSA [15]	Multimodal feature, Cross-modal self-attention on multiple levels and their fusion using learned gates.	2D Image + Language expression	Segmentation mask	Binary cross-entropy loss
Video Classification	Lee *et al.* [182]	Operates on real-valued audio-visual signals instead of tokens, Contrastive learning for pre-training, End-to-end multi-modal transformer learning.	Audio-Visual	Activity labels	Contrastive InfoNCE loss and Binary cross-entropy